VLA 특론 · 4 주차

모방학습과 세 개의 정책

BeT · Diffusion Policy · ACT

VLA 논문을 읽기 위한 문법 시간 — 누적 오차 , 다봉성 , action chunking

140 분 · 읽을 논문 : arXiv 2206.11251 · 2303.04137 · 2304.13705

OPENING

오늘의 지도 (140 분)

0:00	0:10	0:35	0:55	1:05	1:25	1:50	2:10
복습 · 용어	적 1 호 누적 오차	적 2 호 다봉성 + chunking	휴식	해법 1 BeT	해법 2 Diffusion Policy	해법 3 ACT	비교 · 예고
10 분	25 분	20 분	10 분	20 분	25 분	20 분	10 분

오늘의 한 문장

모방학습은 지도학습인데 , 로봇에서는 누적 오차와 다봉성 때문에 실패한다 .
BeT · DP · ACT 는 이산화 · 생성 · CVAE 로 다봉성을 풀었고 , 셋 다 action chunking 을 썼다 .

오늘의 문법 : 네 단어

1

모방학습 (BC)

사람 시범을 지도학습으로 따라 하기

2

누적 오차

작은 실수 → 처음 보는 상태 → 더 큰 실수

3

다봉성

정답 행동이 여러 개 → 평균은 오답

4

Action Chunking

미래 행동 k 개를 한 번에 예측

→ 앞으로 읽을 모든 VLA 논문의 서론과 방법에 이 네 단어가 나온다

용어 정의 : 정책 · 시범 · 모방학습

정책 π(a|s) — 관측 s (카메라 이미지 , 관절 각도) 를 받아 행동 a 를 내는 함수 = 로봇의 두뇌

시범 (demonstration) — 사람이 원격조종 (teleoperation) 으로 로봇을 움직이며 기록한 (s, a) 시퀀스

모방학습 / BC — 시범으로 π 를 지도학습 — "s 를 보면 사람이 했던 a 를 내라 "

원격조종으로 시범을 모으는 방법

리더–팔로워 팔

사람이 작은 팔을 움직이면 로봇 팔이 따라함 (ALOHA)

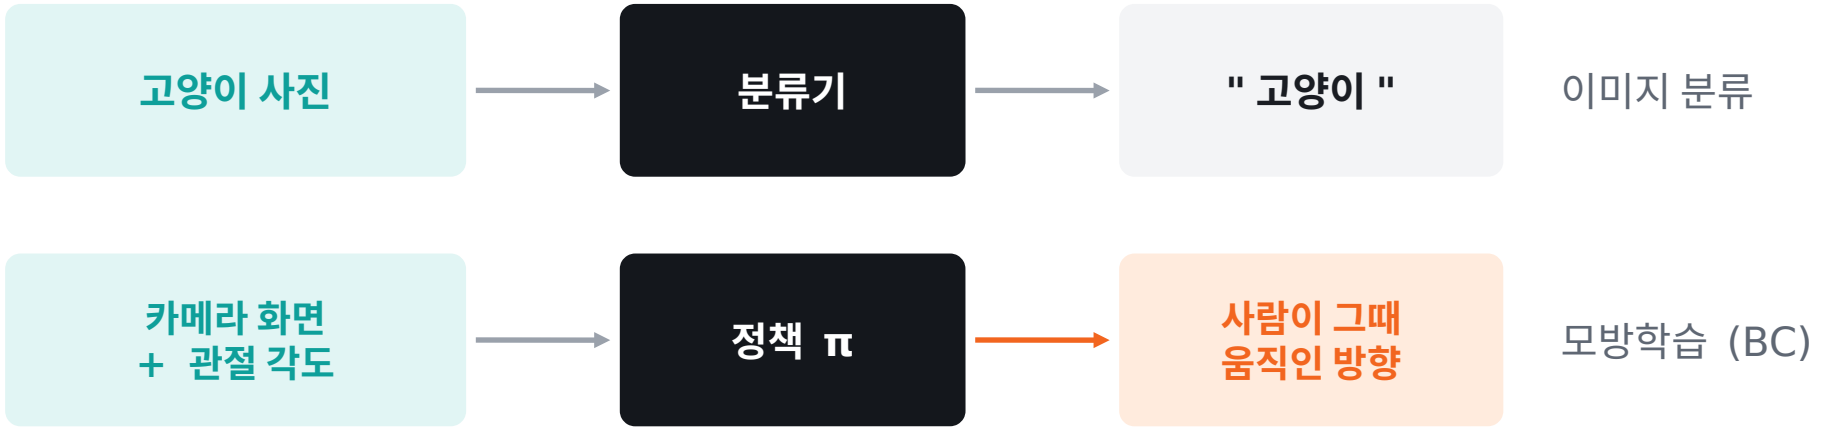
VR 컨트롤러

손 위치를 로봇 손끝으로

스페이스마우스

3D 마우스로 손끝 이동

BC 는 그냥 지도학습이다… 그럼 끝난 것 아닌가 ?




```
min_θ  E_(s,a)~D [ −log π_θ(a | s) ]      또는      || π_θ(s) − a ||²
```

그런데 로봇에서는 이 ' 그냥 지도학습 ' 이 두 가지 방식으로 처참하게 실패한다 → 두 개의 적

PART ①

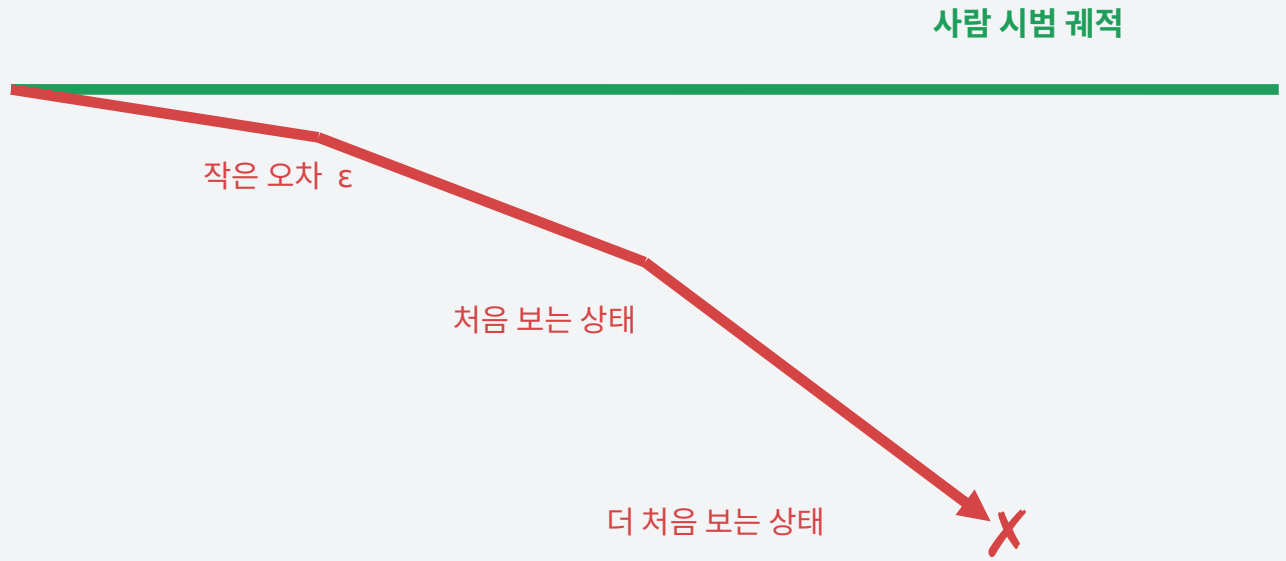
두 개의 적

누적 오차 (covariate shift) 와 다봉성 (multimodality)

0:10 – 0:55 · 슬라이드 7–16

적 1호 · 누적 오차 : 로봇은 자기 시험 문제를 스스로 만든다

지도학습의 대전제 : 훈련 분포 = 테스트 분포



- 정책의 행동이 다음 관측을 결정한다
- 조금 틀림 → 시범에 없던 상태 → 거기선 더 틀림 → 눈덩이
- 시험 문제를 자기 답이 만든다

이름 : covariate shift
(입력 분포가 학습 때와 달라짐)

왜 이렇게 나쁜가 : 복구하는 법이 데이터에 없다

비유 · 운전 교습

- 교습 영상은 전부 차선 한가운데에서 찍혔다
- 영상만 보고 배운 초보가 살짝 차선을 벗어나면 ?
- " 벗어났을 때 돌아오는 장면 " 은 영상에 한 번도 없었다
- **→ 시범자는 실수를 안 하므로 , 실수 복구법이 데이터에 없다**

이론 한 줄 (Ross & Bagnell, 2010)

한 스텝 실수 확률 ε, 에피소드 길이 T

εT

일반 지도학습

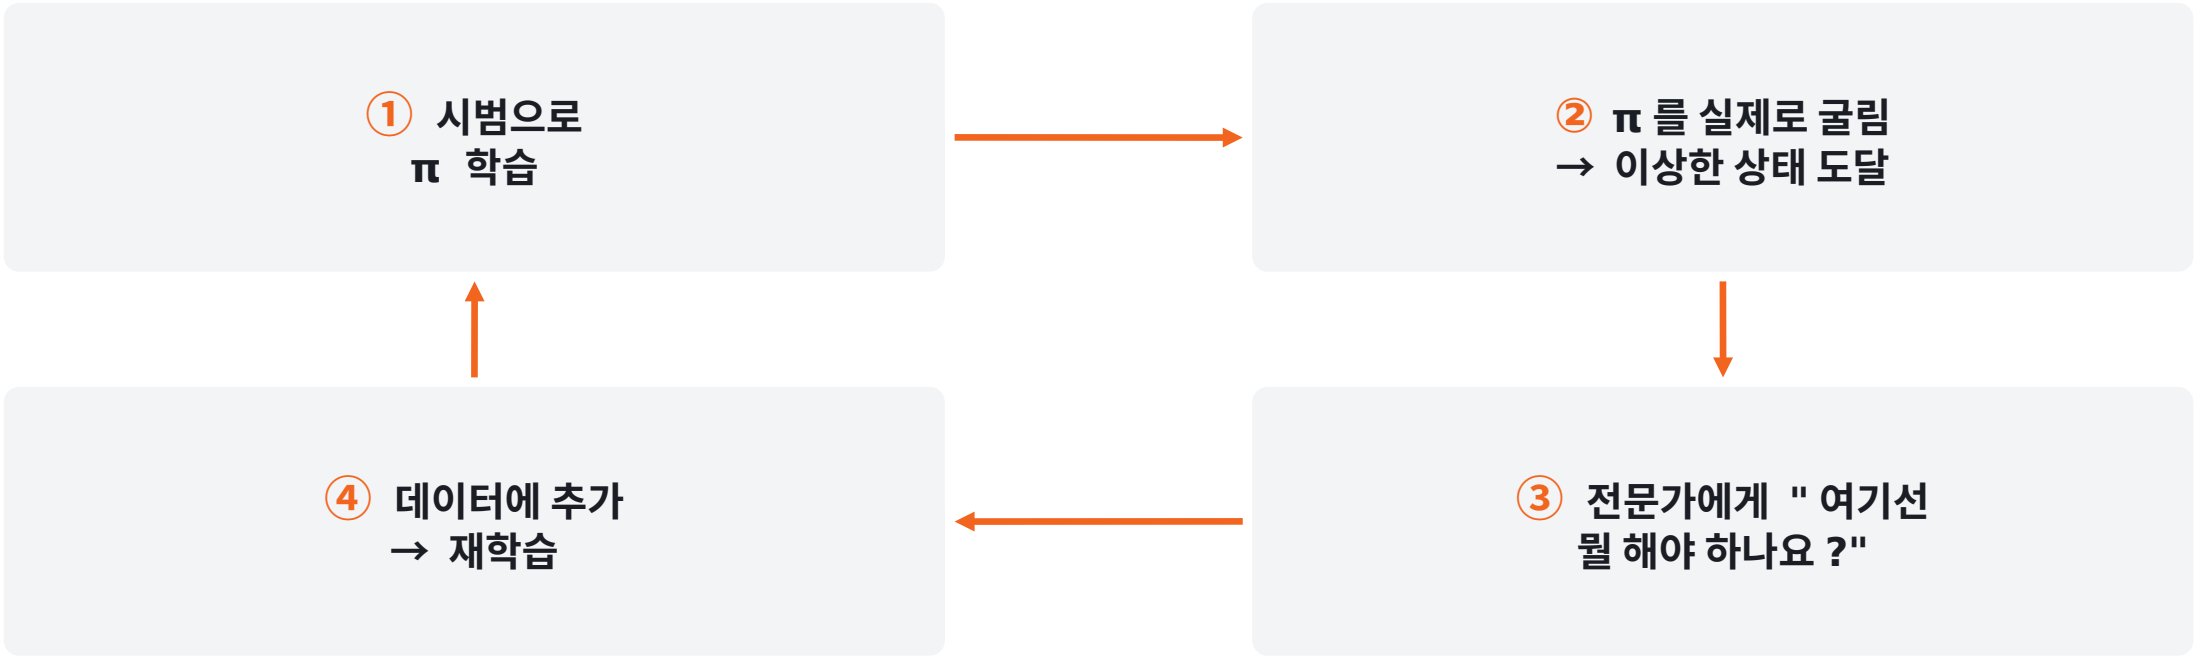
εT^2

BC (최악의 경우)

학생에게 : " 그럼 어떻게 해결할까요 ?" → " 실수 장면도 넣자 " · " 사람이 계속 고쳐주자 "

Ross, Gordon, Bagnell · 2011

고전적 해법 : DAgger — 로봇이 간 곳에서 라벨을 받아라



장점

로봇이 실제로 가는 상태 분포에서 라벨 → 원리적으로 옳다

단점

전문가가 로봇 옆에 계속 대기해야 한다 → 비싸다

현대적 처방 두 가지

처방 1 · 데이터를 다양하게

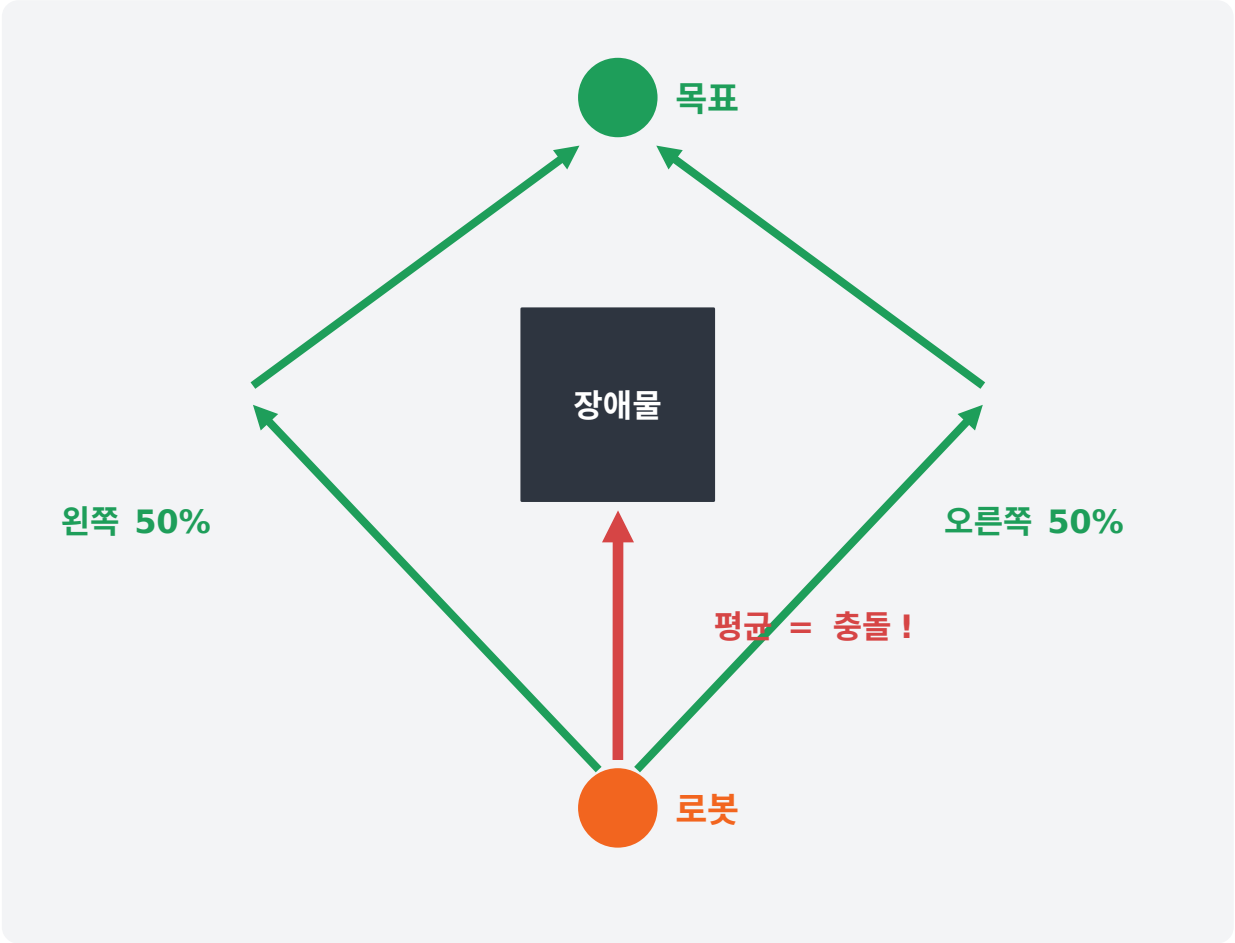
- 실수 · 복구 장면까지 포함해 많이 모은다
- 여러 사람 , 여러 환경 , 여러 로봇
- **→ 9–11 주차 데이터 스케일링의 확장판**

처방 2 · 여러 스텝을 한 번에 예측

- 한 스텝씩 결정하면 오차가 끼어들 기회가 T 번
- k 스텝씩 결정하면 T/k 번으로 줄어든다
- **→ 잠시 후 action chunking**

체크 : 왜 사람 시범 데이터에는 복구 장면이 없나요 ? → 사람은 잘하니까

적 2 호 · 다봉성 : 평균은 정답이 아니다



MSE 회귀가 배우는 것

```
argmin_f E|| f(s) − a ||²  =  E[a | s]
```

- MSE 의 최적해는 조건부 평균
- 정답 분포의 봉우리가 둘이면 , 평균은 두 봉우리 사이 골짜기
- 골짜기 = 시범에 한 번도 없던 행동

지난주 (2 주차) 질문의 재등장

로봇 조작은 다봉성 투성이다

잡는 방법

컵을 위에서 · 옆에서 · 손잡이로 → 모두 정답

여러 시범자

사람마다 스타일이 다르다

같은 사람도

그날그날 다르게 한다 (손떨림 , 속도)

순서

부엌 정리 : 전자레인지 먼저 ? 주전자 먼저 ?
(BeT 의 Franka Kitchen 실험)

시범 데이터의 행동 분포는 거의 항상 봉우리가 여러 개다

시간 축의 다봉성 : 갈팡질팡 (dithering)

매 스텝 독립적으로 샘플링하면…

t = 1	t = 2	t = 3	t = 4	t = 5
왼쪽 !	**오른쪽 !**	**왼쪽 !**	**오른쪽 !**	**왼쪽 !**

→ **로봇은 제자리에서 덜덜덜**

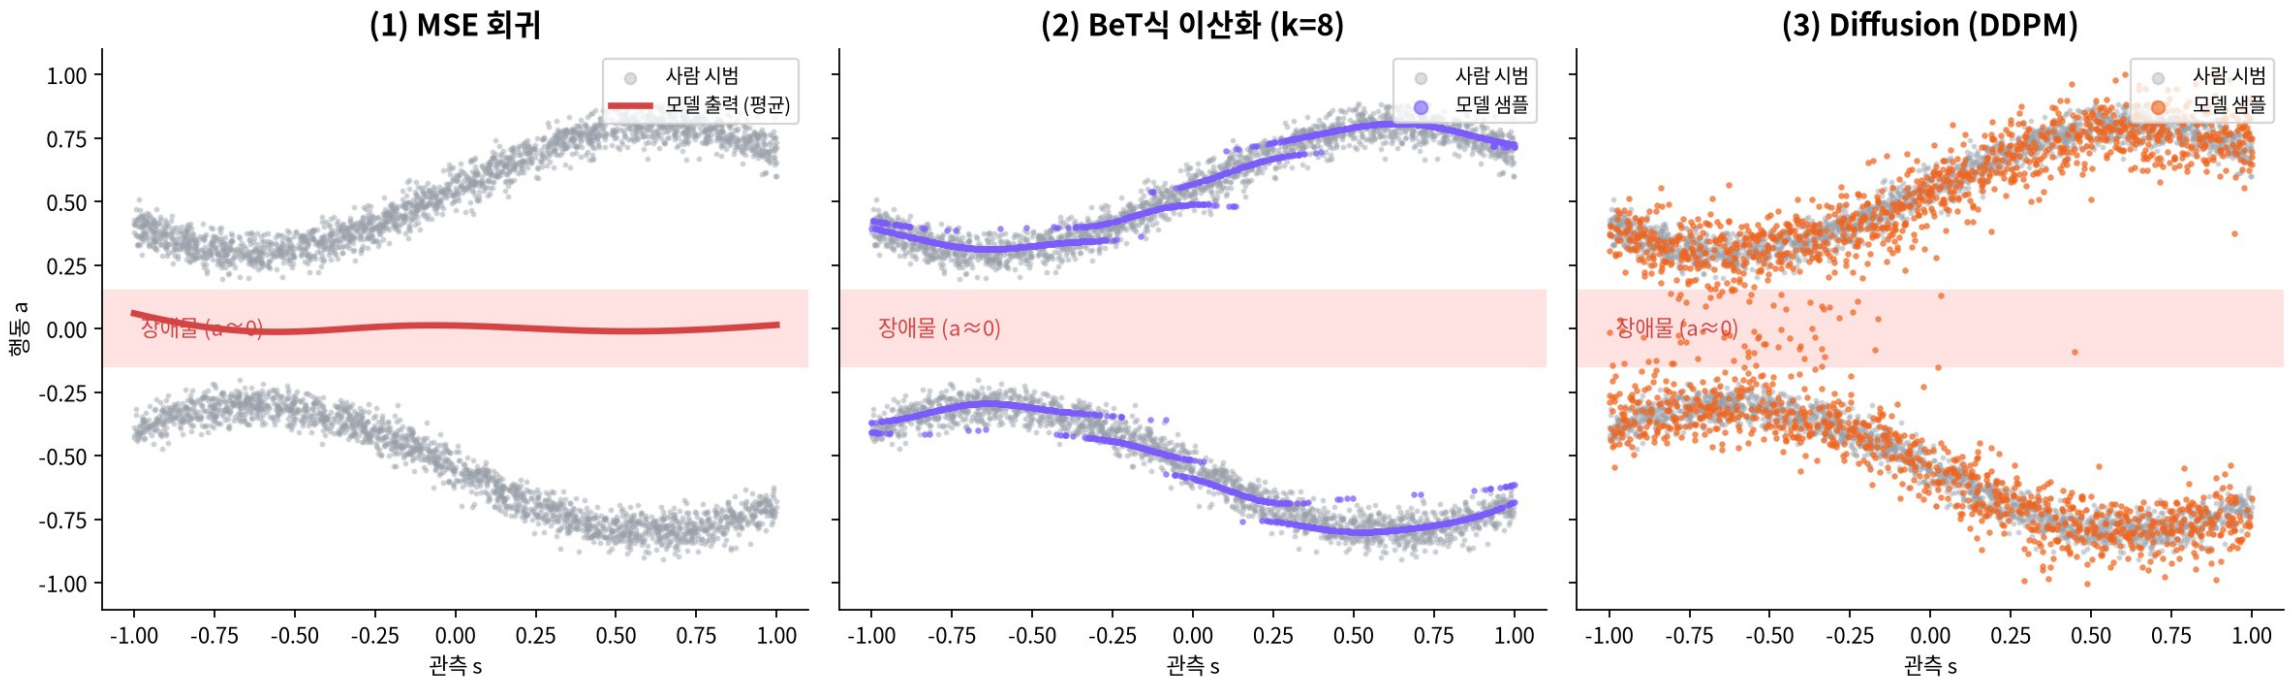
필요한 것 1 · 봉우리 고르기

여러 정답 중 하나를 확실히 선택한다

필요한 것 2 · 고른 봉우리 유지하기

한 번 고른 계획을 한동안 지킨다 (시간적 일관성)
→ 세 논문 모두를 action chunking 으로 이끈 관찰

데모 : 같은 데이터 , 같은 크기의 신경망 , 출력 표현만 다르게



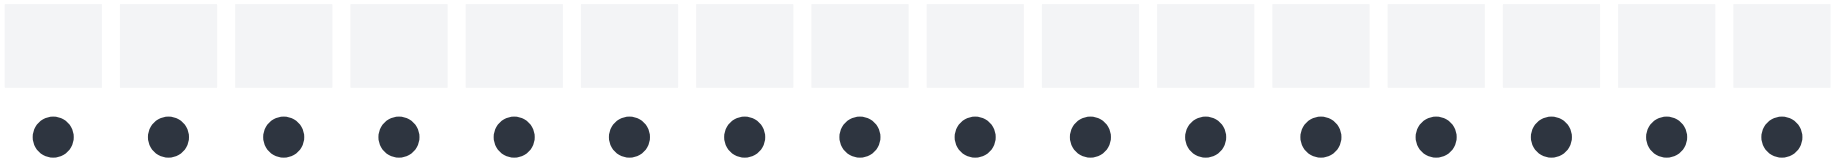
장애물 구간 (a ≈ 0) 에 떨어진 행동 비율

100% MSE 회귀 **0%** BeT 식 이산화 **3%** Diffusion

demo/multimodality_demo.py (numpy 만 , CPU 40 초)

Action Chunking: 미래 k 개를 한 번에

한 스텝씩



● = 모델 추론 (16 번)

k = 8 씩



● = 모델 추론 (2 번) · 한 뭉치 = 하나의 계획

Action Chunking

현재 관측 s 를 보고 행동 1 개가 아니라 미래 행동 k 개 (예 : k = 16 ~ 100) 를 한 번에 예측하는 것

Chunking 의 세 가지 효과 — 두 적 모두에 듣는다

효과 1

누적 오차 감소

결정 횟수 1/k → 오차가 끼어들 기회 감소

적 1 호 대응

효과 2

시간적 일관성

한 뭉치 = 하나의 계획에서 나옴 → 갈팡질팡 방지

적 2 호 대응

효과 3

실시간 제어

추론 1 번으로 k 스텝 커버 → 무거운 모델도 버팀

후반부 복선 (VLA)

	Diffusion Policy	ACT	π0 (7 주차)
chunk 길이	16 생성 / 8 실행	100	50
제어 주파수	~10Hz	50Hz	50Hz
초 단위	~0.8 초 실행	2 초	1 초



10 분 휴식

쉬는 동안 생각해보기

k-means 로 행동을 8 개 군집으로 나누면 ,
모델은 '8 지선다 객관식 ' 을 푸는 셈입니다 .
이 방법의 약점은 무엇일까요 ?

PART ②

세 개의 해법

BeT

행동을 양자화하라

이산화 + 오프셋

Diffusion Policy

행동을 생성하라

조건부 diffusion

ACT

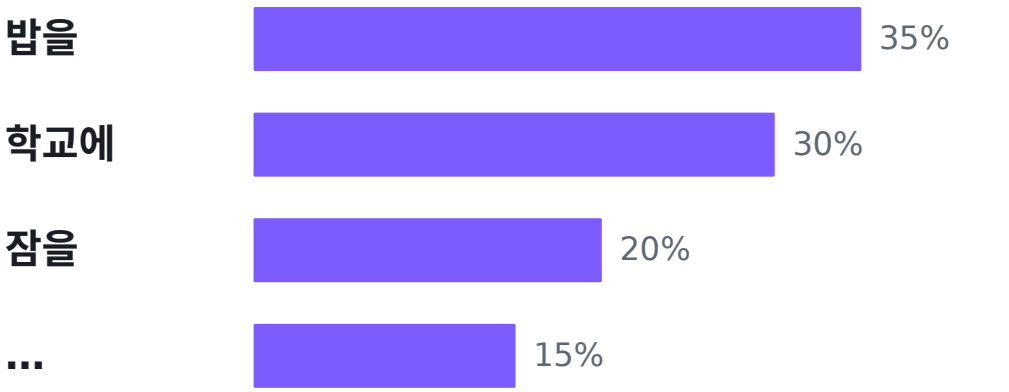
행동을 뭉치로 예측하라

chunk 회귀 + CVAE

1:05 – 2:10 · 슬라이드 19–36

BeT: 언어 모델은 다봉성을 어떻게 다루지 ?

"나는 오늘 ___"

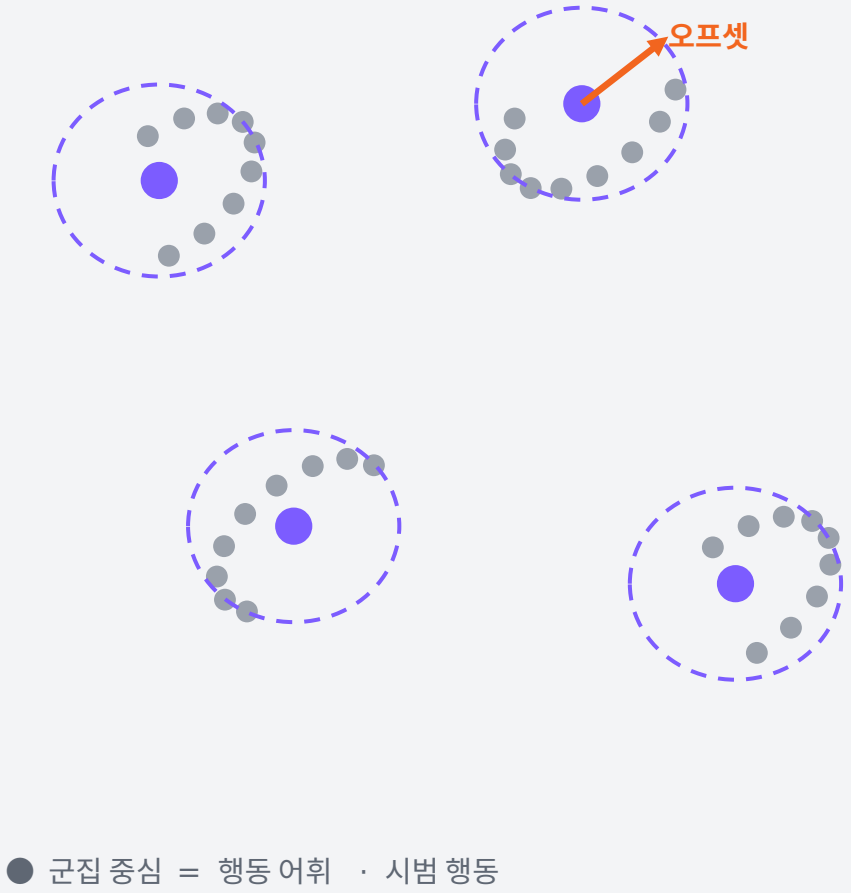


softmax: 여러 후보에 확률을 나눠 준다 → 전혀 곤란하지 않다

BeT 의 발상

- 언어 모델이 다봉성에 강한 이유는 어휘가 이산적이라서
- 그렇다면 연속 행동도 ' 어휘 ' 로 만들자
- Transformer 는 그대로 , 출력만 분류로
- **→ "k 개의 모드를 돌 하나로 복제한다 "**

BeT 의 방법 : 동네를 고르고 , 번지수를 찍는다



① k-means 양자화

시범의 모든 행동 벡터 → k 개 대표 행동 (군집 중심) = " 행동 사전 "

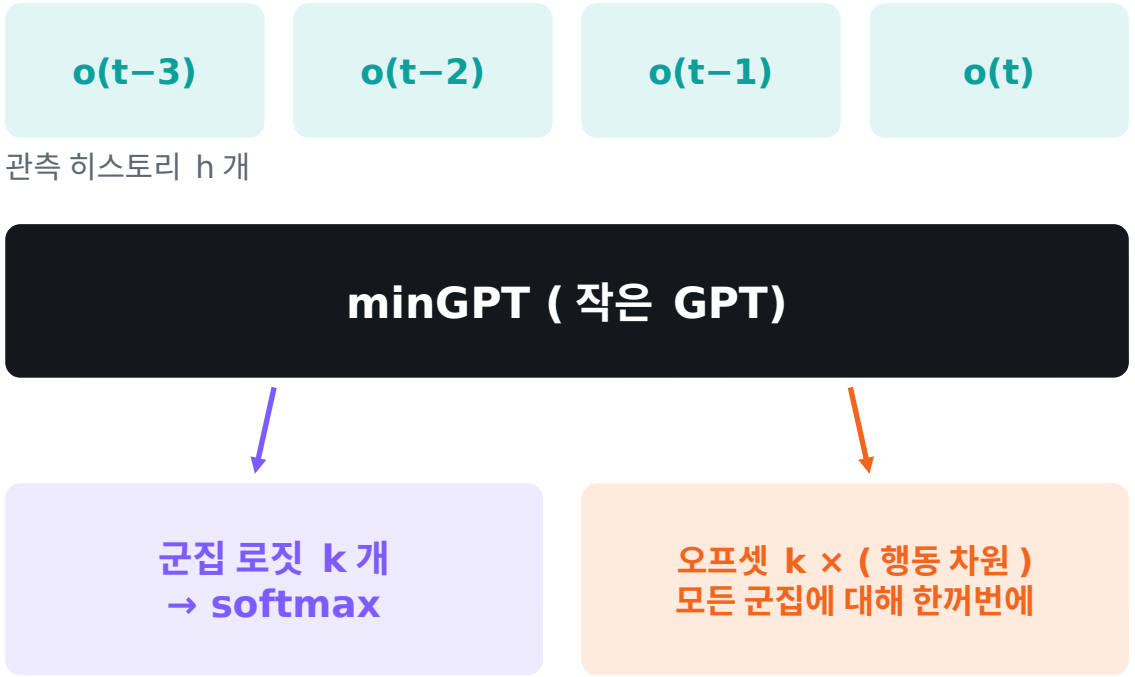
② Transformer 가 관측 히스토리를 보고

- (a) 어느 군집인가 ? → softmax 분류 → 봉우리 고르기
- (b) 중심에서 얼마나 ? → 잔차 오프셋 회귀 → 정밀도 복원

```
행동 = 중심[j] + 오프셋[j],  j ~ softmax
```

비유 : 지도에서 ' 어느 동네 ' 인지 고르고 (이산), 동네 안 번지수를 찍는다 (연속)

BeT 의 구조와 손실



손실

$$L = \text{Focal}(p, j^*) + \lambda \cdot \| \hat{r}[j^*] - (a - c[j^*]) \|^2$$

- Focal loss: 이미 잘 맞히는 쉬운 샘플의 가중치를 낮춰 드문 군집도 배우게 하는 분류 손실
- 오프셋은 정답 군집 j^* 의 것만 학습 (masked)
- 학습 땐 정답 군집 오프셋 , 실행 땐 뽑힌 군집 오프셋 사용
- 히스토리를 보는 이유 : 지금 어느 모드 (순서) 를 수행 중인지 알아야 함

BeT 의 실험 , 의의 , 한계

CARLA 자율주행

건물을 왼쪽 / 오른쪽으로 돌아가는 두 경로

블록 밀기

어느 블록을 어느 목표 칸으로 먼저

Franka Kitchen

7 개 하위작업을 어떤 순서로

결과 : 기존 BC(MLP) 는 모드가 섞여 실패 , BeT 는 시범에 있던 여러 모드 (경로 · 순서) 를 골고루 재현 (시뮬레이션)

의의

" 행동 이산화 " 계보의 시조 → 6 주차 RT-1 · RT-2 · OpenVLA 의 256-bin (더 단순한 균등 구간)

한계

k 에 민감 · 정밀 조작에서 이산화 손실 · 원 논문은 목표 / 언어 조건 없음

후속

C-BeT (목표 조건 , 실제 로봇)
VQ-BeT (2024, 잔차 벡터 양자화로 k-means 대체)

Diffusion Policy: 관측을 조건으로 행동 시퀀스를 생성한다

2 주차

노이즈 이미지 x_T → (denoise × K) → 이미지 x_0

조건 c = 텍스트

오늘

노이즈 행동열 A_K → (denoise × K) → 행동 시퀀스 A_0

조건 c = 최근 관측
(이미지 2 장 + 로봇 상태)

$$L = || \varepsilon - \varepsilon_\theta(A_k, k, \text{관측}) ||^2$$ ← 2 주차 손실과 글자 하나 다르지 않다

조건부 생성모델 = 로봇 정책 (2 주차 칠판의 등식이 논문이 된 것)

작동 흐름 : 계획은 길게 , 실행은 앞부분만 (receding horizon)



왜 16 개 만들고 8 개만 쓰나

- 길게 계획 → 일관성 (한 모드를 유지)
- 짧게 실행 → 반응성 (새 관측을 빨리 반영)

비유

내비게이션이 전체 경로를 그려주지만 , 몇 초마다 다시 계산한다

Diffusion Policy 는 왜 잘 되나

1 다봉성

분포 자체를 배운다 → 데모 그림 (3)

2 시간적 일관성

16 스텝을 한 덩어리로 생성 → chunking 내장

3 정밀도

이산화가 없다 → 연속 행동 그대로

4 학습 안정성

에너지 대신 score 를 배운다 (다음 슬라이드)

3 주차 연결 : 에너지 대신 score 를 배운다

이전 : IBC (암묵적 정책 , 에너지 모델)

- $p(a|o) \propto \exp(-E(a, o))$
- 정규화 상수 $Z(o) = \int \exp(-E)\, da$ 계산이 어렵다
- 음성 샘플로 Z 를 근사 → 학습 불안정

Diffusion Policy

- $\nabla_a \log p(a|o) = -\nabla_a E(a, o)$
- 미분하면 Z 가 사라진다 (상수이므로)
- 노이즈 예측 = score 학습 → 음성 샘플 불필요 , 안정적

3 주차 : "diffusion 학습 = score 학습 " → 여기서 실용적 이득 (안정성) 으로 나타난다

Diffusion Policy 의 결과

+46.9%
기존 최고 방법 대비 평균 향상

15 개
과제 (4 개 벤치마크)

3 개
비교 대상 : LSTM-GMM · IBC · BET

시뮬레이션 벤치마크

- Robomimic: Lift · Can · Square · Transport · ToolHang
- Push-T: T 자 블록을 목표에 밀어 넣기
- Multimodal Block Pushing · Franka Kitchen

실제 로봇

- Push-T · 머그컵 뒤집기 · 소스 붓기 · 펴 바르기
- 사람이 방해해도 재계획으로 복구
- 확장판 (IJRR): 양팔 과제 추가

▶ 영상 : diffusion-policy.cs.columbia.edu

구조 두 가지와 실무 팁

	CNN 기반 (1D 시간축 U-Net)	Transformer 기반
조건 주입	FiLM: 관측으로 채널 scale/bias 조절	cross-attention: 행동 토큰 → 관측
추천	기본값 , 하이퍼파라미터에 덜 민감	행동이 급변하는 과제 , 튜닝 필요

비전 인코더

- ResNet-18 을 사전학습 없이 정책과 함께 학습
- 전역 풀링 → spatial softmax (" 어디 " 정보 보존)
- BatchNorm → GroupNorm

위치 제어 > 속도 제어

- " 이 각도로 가라 "(절대) vs " 이만큼 더 "(델타)
- 델타는 오차가 적분되어 누적 오차에 취약
- 위치 제어가 행동 시퀀스 예측과 궁합이 좋음

약점 : 2 주차에 심어 둔 걱정이 돌아왔다

K = 100

학습 시 denoising 스텝

10 스텝

실행 시 DDIM 으로 축소

~0.1 초

chunk 하나 생성 (RTX 3080)

" 로봇은 0.02 초마다 행동을 내야 하는데 ?" → chunking 으로 상쇄하지만 근본적으로 반복적

이후의 해답

- 3 주차 flow matching → π0 (약 10 스텝)
- 12 주차 효율화 · 비동기 실행 (RTC)

유산

- 소규모 모방학습의 사실상 기본 베이스라인
- Octo 의 diffusion head · GR00T 의 DiT head · UMI

ACT: 하드웨어가 반이다 — ALOHA

리더 팔 × 2
(사람이 잡고 움직임)

관절 1:1 →

팔로워 팔 × 2
(ViperX 6 자유도)

4 대
카메라 (위 · 앞 · 양 손목)

50Hz
제어 주파수

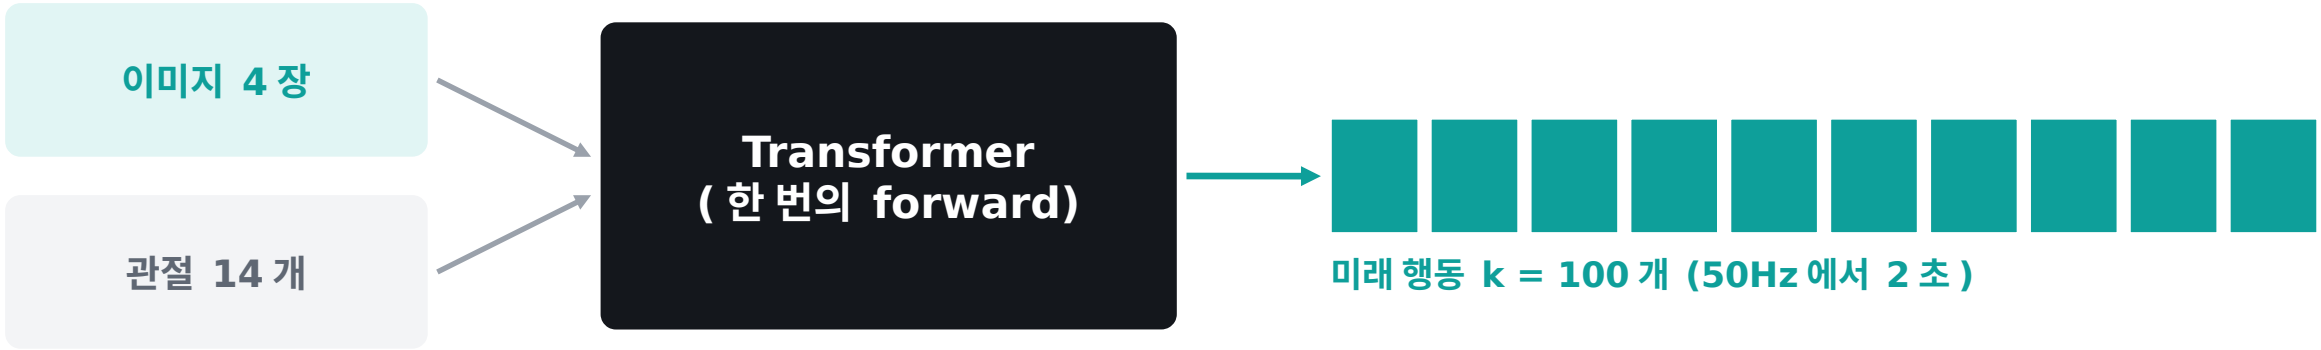
<$20k
총 비용 (기성품 +3D 프린팅)

실제 과제 6 개

- 지퍼백 열기
- 건전지 끼우기
- 투명 소스컵 뚜껑 열기
- 벨크로 (케이블 타이) 끼우기
- 테이프 뜯어 붙이기
- 신발 신기기

저가 로봇은 부정확하다 → 학습으로 보상할 수 있을까 ? 정밀 과제일수록 누적 오차가 치명적 → chunking 이 주인공이 된 이유

ACT = Action Chunking with Transformers



회귀

diffusion 처럼 반복하지 않는다 → 빠름 .
손실은 L1 (정밀 과제에서 L2 보다 좋음)

장치 1 · CVAE

사람 시범의 들쭉날쭉함 (스타일) 을
잠재변수 z 로 흡수

장치 2 · 시간 앙상블

Temporal ensembling: 겹치는 예측을
가중평균해 부드럽게 실행

5 분 보충 : VAE 란 ?



- 데이터를 짧은 요약 벡터 z 로 압축했다가 , z 에서 다시 복원하도록 학습하는 오토인코더의 확률 버전
- z 가 표준정규분포 N(0, I) 에서 너무 멀어지지 않게 KL 벌점을 준다
- CVAE(조건부 VAE): 인코더 · 디코더에 조건 (여기선 관측) 을 함께 넣는다

ACT 에서는 z = " 시범의 스타일 요약 " 이라고만 이해하면 충분

ACT 의 CVAE: 훈련 때와 실행 때가 다르다

훈련

실제 시범 행동 100 개 + 관절 → 인코더 → z (32 차원) " 빠르게 / 조심스럽게 " → 디코더 (+ 이미지 · 관절) → 행동 100 개 복원

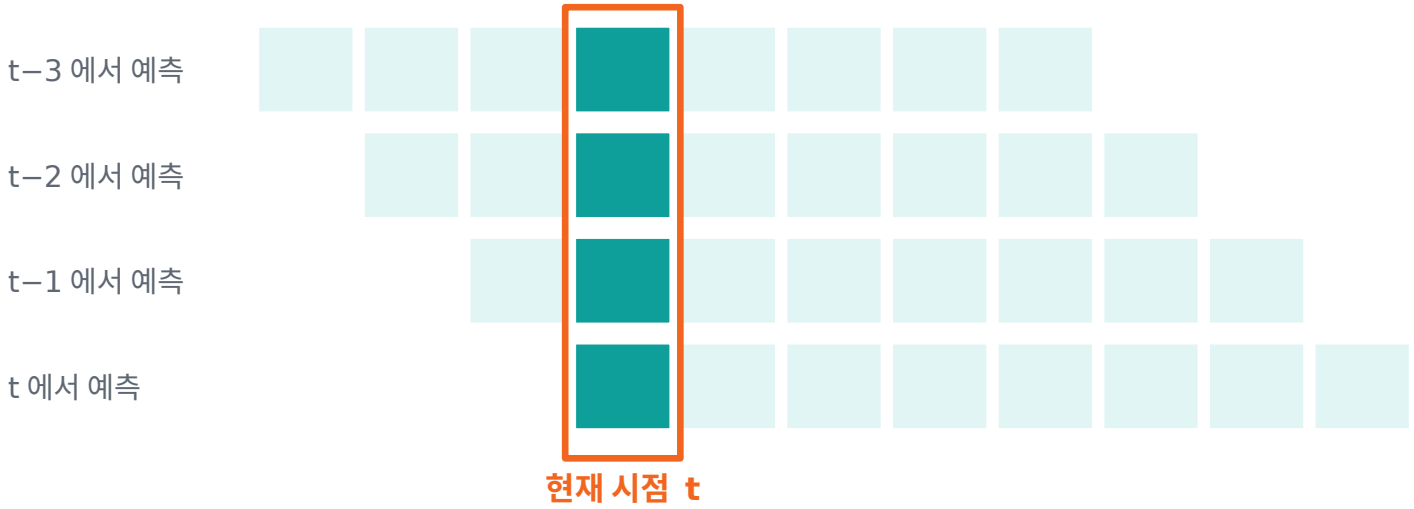
실행

인코더 없음

z = 0 (평균 스타일) → 디코더 → 행동 100 개

```
L = L1( 복원 ) + β · KL( q(z | 행동, 관절) || N(0, I) ),   β = 10
```

Temporal Ensembling: 겹치는 예측을 평균해 부드럽게




```
a_t = Σ w_i · Â_t(i) / Σ w_i
w_i = exp(−m · i),  i=0 이 가장 오래된 예측
```

m 이 작을수록 새 관측을 빨리 반영 · 추가 학습 비용 없음

Diffusion Policy

8 개 실행 후 새로 → 끊어서 실행

ACT

매 스텝 새 chunk 예측 + 겹친 예측 평균 → 부드럽게 실행

ACT 의 결과와 ablation

50 개
과제당 시범 (약 10 분 분량)

80–90%
정밀 양팔 과제 성공률 (대부분)

~0%
비교 방법 대부분 (BeT · RT-1 · VINN 등)

가장 어려운 벨크로 끼우기는 20% 대

chunk 크기	k=1 에서 매우 낮고 , k 를 키울수록 크게 향상 . 다른 방법에 붙여도 좋아짐 → 일반 원리
CVAE	스크립트 데이터 (일관됨) 에선 차이 없음 , 사람 데이터에선 빼면 급락 → 들쭉날쭉함을 흡수
제어 주파수	사람도 5Hz 조종은 50Hz 보다 훨씬 어려움 → 고주파가 정밀 조작에 중요

ACT 의 한계와 유산

한계

- 과제별 학습 , 언어 조건 없음
- 실행 시 $z = 0$ → 사실상 한 가지 스타일
- 좌 / 우처럼 완전히 다른 모드엔 여전히 위험

후속

- Mobile ALOHA (2024): 바퀴 달린 전신 조작
- ALOHA 2 (2024): Gemini Robotics 의 플랫폼
- ALOHA Unleashed (2024): 대규모 데이터 + diffusion

가장 큰 유산

action chunking → π0 의 50 스텝 @ 50Hz, 거의 모든 VLA
LeRobot 의 기본 정책 → 저가 SO-100/101 팔 입문의 표준

세 해법 비교

	BeT	Diffusion Policy	ACT
다봉성 해법	이산화 (분류) + 오프셋	분포 자체를 생성	CVAE 로 스타일 흡수
출력	행동 토큰 (+ 잔차)	행동 시퀀스 생성 (16)	행동 chunk 회귀 (100)
실행 방식	매 스텝	8 스텝 실행 후 재계획	매 스텝 + temporal ensembling
속도	빠름	느림 (반복 denoising)	빠름 (1 회 forward)
손실	focal + 오프셋 MSE	ε 예측 MSE	L1 + β·KL
유산	RT 류의 행동 이산화	Octo · GR00T · π0 의 생성 head	모든 VLA 의 chunking

세 논문이 공유한 것 , 그리고 6 주차로

다봉성을 푸는 방법은 달랐지만 , 셋 다 여러 스텝을 한 번에 예측했다 (action chunking)

작은 모델
한 과제
수십 ~ 수백 시범

+ 1 주차 VLM



VLA
한 모델 · 수백 과제
언어 명령

6 주차 : RT-1 → RT-2 → Octo → OpenVLA

논문 읽기 습관 : 행동 표현 (이산 / 생성 / 회귀)? chunk 길이 ? 제어 주파수 ? 초 단위로 환산 !

마무리 O / X

1	BC 는 지도학습이므로 훈련 · 테스트 분포가 항상 같다 .	X	정책이 자기 테스트 분포를 만든다
2	MSE 회귀는 다봉성 데이터에서 두 모드 중 하나를 고른다 .	X	평균을 낸다
3	BeT 는 행동을 군집으로 나누고 오프셋으로 정밀도를 보완한다 .	O	
4	Diffusion Policy 는 행동 16 개를 생성해 16 개를 모두 실행한다 .	X	앞 8 개만 실행
5	ACT 의 chunk 100 은 50Hz 에서 2 초 분량이다 .	O	

다음 주 · 5 주차

강화학습 기초 : 시행착오에서 배우기

" 모방학습의 천장은 시범자의 실력입니다 . 사람보다 잘할 수 없고 , 사람이 안 보여준 상황엔 약합니다 .
그 천장을 뚫는 도구가 강화학습입니다 . 14 주차 세미나 논문들이 전부 다음 주 언어로 쓰여 있습니다 ."

과제 (선택): 리딩 리포트 반 페이지 — BeT / Diffusion Policy / ACT 중 1 편

