Basics of

Vision-Language-Action Models

보고 , 이해하고 , 움직이는 로봇 AI — RT-2 부터 π0.5, 그리고 그 너머까지

강의자 이름 · 소속 · 2026

OPENING

오늘의 로드맵 (120 분)

PART 1

왜 VLA 인가

20 분

PART 2

VLA 의 구성요소

25 분

BREAK

휴식

10 분

PART 3

논문으로 보는 VLA 의 진화

45 분

PART 4

평가 · 한계 · 미래

15 분

+ 마무리 요약 & Q&A 5 분

- Part 1–2: 개념과 원리 (무엇을, 왜)
- Part 3: 대표 논문 12 편으로 흐름 잡기 (어떻게 발전했나)

OPENING

오늘이 끝나면 여러분은…

1

VLA 가 무엇인지

이미지 + 언어 + 로봇 상태 → 행동 . 한 문장으로 설명할 수 있다 .

2

행동을 출력하는 4 가지 방식

이산 토큰 · 연속 회귀 · 디퓨전 / 플로우 · 압축 토큰 (FAST) 의 차이를 안다 .

3

대표 논문의 계보

RT-2 → OpenVLA → π0 → π0.5 → 이중 시스템 → RL 까지 흐름을 설명할 수 있다 .

로봇에게 " 식탁 좀 치워줘 " 라고 말하면 ?

“ 식탁 좀 치워줘”

- 어떤 게 쓰레기고 어떤 게 그릇인지 알아야 하고 (Vision + 상식)
- " 치운다 " 가 무슨 뜻인지 이해해야 하고 (Language)
- 처음 보는 컵도 깨지지 않게 집어야 한다 (Action)



이 세 가지를 하나의 모델로 → VLA

▶ 영상 : π0.5 — 처음 보는 집 청소 (pi.website/blog/pi05)

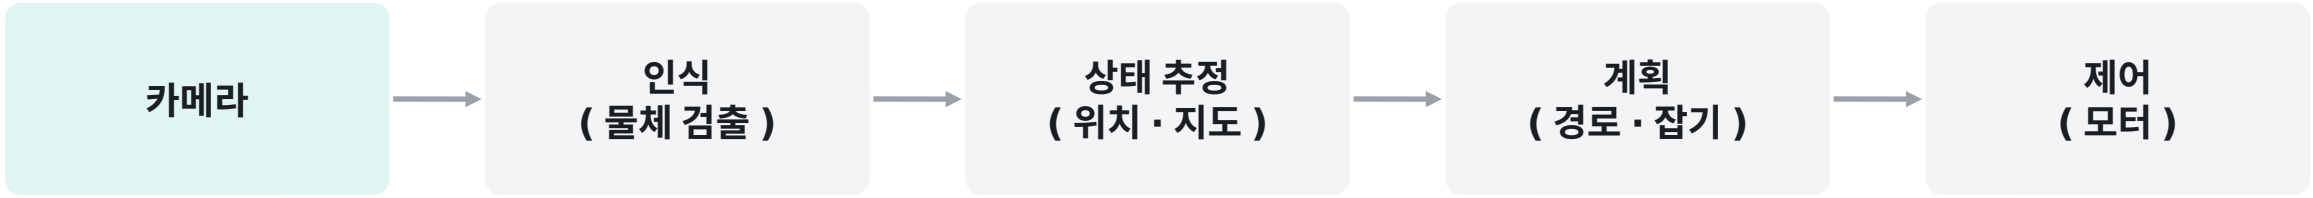
PART 1

왜 VLA 인가

LLM 은 시를 쓰는데 , 왜 로봇은 아직 빨래를 못 갤까 ?

약 20 분 · 슬라이드 6–13

전통적인 로봇 : 사람이 설계한 모듈의 파이프라인



각 모듈을 사람이 설계 · 튜닝

장점

- 공장처럼 고정된 환경에서 정확하고 빠름
- 각 단계를 해석 · 디버깅하기 쉬움

한계

- 새 물체 · 새 환경마다 다시 설계 (컵 → 비닐봉지 ? 수건 ?)
- 모듈 간 오류 누적 (인식 1cm 오차 → 잡기 실패)
- " 식탁 치워줘 " 같은 애매한 언어를 이해 못 함

모라벡의 역설 : 사람에게 쉬운 일이 AI 에겐 어렵다

AI 가 이미 해낸 것

1997 체스 세계 챔피언 격파

2016 바둑 (AlphaGo)

2022~ 시 · 코드 · 논문 작성 (LLM)

아직 어려운 것

- 빨래 개기 (모양이 계속 변함)
- 처음 보는 집에서 설거지
- 계란을 깨지 않고 집기
- 이 모든 걸 하나의 모델로

이유 : 물리 세계는 연속적 · 예측 어려움 · 데이터 비쌈 · 실수 비용 큼

LLM 의 성공 레시피를 로봇에도 쓸 수 있을까 ?

LLM

대규모 사전학습
인터넷 텍스트 수조 토큰

→

사후학습
지시 따르기 · 대화 · RL

→

범용 모델
하나의 모델로 수많은 작업

로봇에 그대로 적용하려면 두 가지 벽이 있다

벽 1 · 데이터

로봇 데이터는 인터넷에 공짜로 쌓여 있지 않다 . 사람이 직접 조종해서 모아야 한다 .

벽 2 · 출력

로봇의 출력은 단어가 아니라 연속적인 모터 명령이다 .

아이디어 : 이미 인터넷으로 학습된 VLM 을 가져와서 , 로봇 행동만 추가로 가르치자 ! → VLA

VLA 의 정의




```
π(a[t:t+H] | 이미지, 언어, 상태)
```

용어의 기원 : RT-2 (Google DeepMind, 2023)

보통 사전학습된 VLM 위에 만든다 → 인터넷 지식을 로봇이 활용

LLM · VLM · VLA 무엇이 다른가

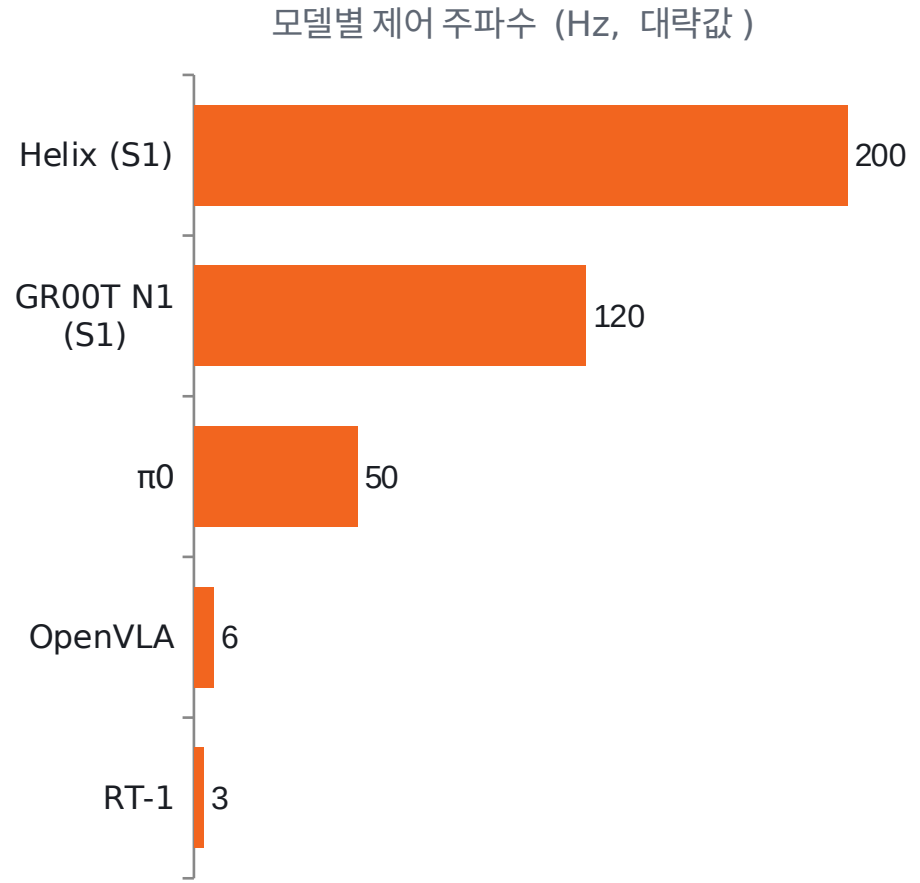
	LLM	VLM	VLA
입력	텍스트	이미지 + 텍스트	이미지 + 텍스트 + 로봇 상태
출력	텍스트	텍스트	로봇 행동 (+ 때로 텍스트)
예시	GPT, Llama, Claude	LLaVA, PaliGemma, Qwen-VL	RT-2, OpenVLA, π0, GR00T
틀리면 ?	오답 문장	오답 문장	컵이 깨진다 (물리적 결과)
학습 데이터	수조 토큰	이미지 - 텍스트 수십억 쌍	로봇 시연 수십만 ~ 수백만 에피소드
동작 방식	한 번 답하면 끝	한 번 답하면 끝	닫힌 루프 : 행동 → 세상 변화 → 새 관측

로봇의 " 행동 (Action)" 이란 ?

가장 흔한 표현 : 손끝 (엔드 이펙터) 의 7 차원 변화량

Δx	Δy	Δz	Δroll	Δpitch	Δyaw	grip
앞뒤	좌우	위아래	회전	회전	회전	열기 / 닫기

- 다른 표현 : 관절 각도 (팔 7 개 관절), 양팔은 14 차원 , 휴머노이드는 수십 차원
- Embodiment(몸의 형태) 마다 행동 공간이 다르다 → 여러 로봇 데이터를 합치기 어려움
- 제어 주파수 (Hz): 1 초에 몇 번 행동을 내보내나 — 정교한 작업일수록 높아야 함



로봇 데이터는 어디서 오나 : 데이터 격차

~15 조

LLM 사전학습 텍스트 토큰
(예 : Llama 3) — 인터넷에서 사실상 공짜

~100 만

공개 로봇 데이터 최대 규모 궤적 수
(Open X-Embodiment, 2023)

~1 만 시간

π0 자체 수집 로봇 데이터
(업계 최대급 , 비공개)

로봇 데이터 = 사람이 직접 조종 (Teleoperation) 해서 한 에피소드씩

리더–팔로워 팔

ALOHA: 사람이 리더 팔을 움직이면 로봇 팔이 그대로 따라함 . 저가 · 양팔

VR · 스페이스마우스

VR 컨트롤러나 3D 마우스로 손끝 위치를 직접 지정

한 에피소드 =

(이미지들 , 로봇 상태들 , 행동들 , 언어 지시) 의 시계열 기록

모방학습 (Behavior Cloning) 과 두 가지 함정

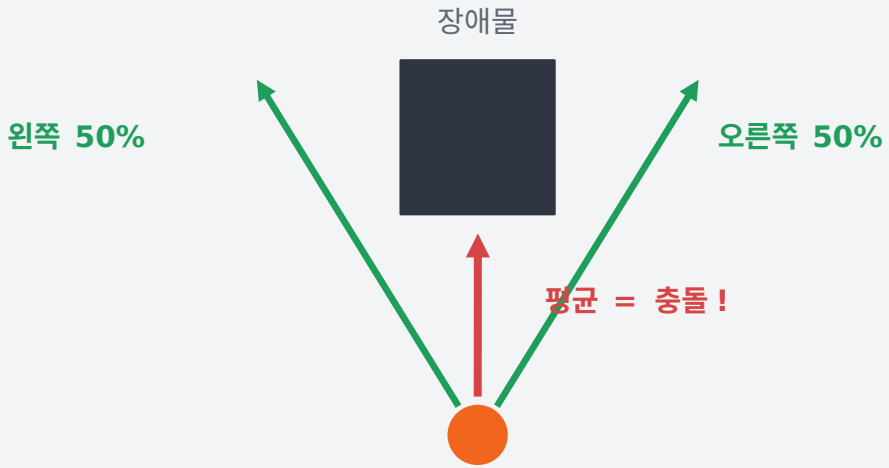
" 이 장면에서 사람은 이렇게 움직였으니 , 너도 그렇게 해 " — 시연 데이터로 지도학습

함정 1 · 누적 오차



조금 틀림 → 처음 보는 상황 → 더 틀림 → 눈덩이
(차선 중앙만 연습한 운전자)

함정 2 · 다봉성 (정답이 여러 개)



MSE 회귀로 배우면 두 정답의 평균을 출력
→ 분포를 표현하는 출력 방식이 필요 (Part 2)

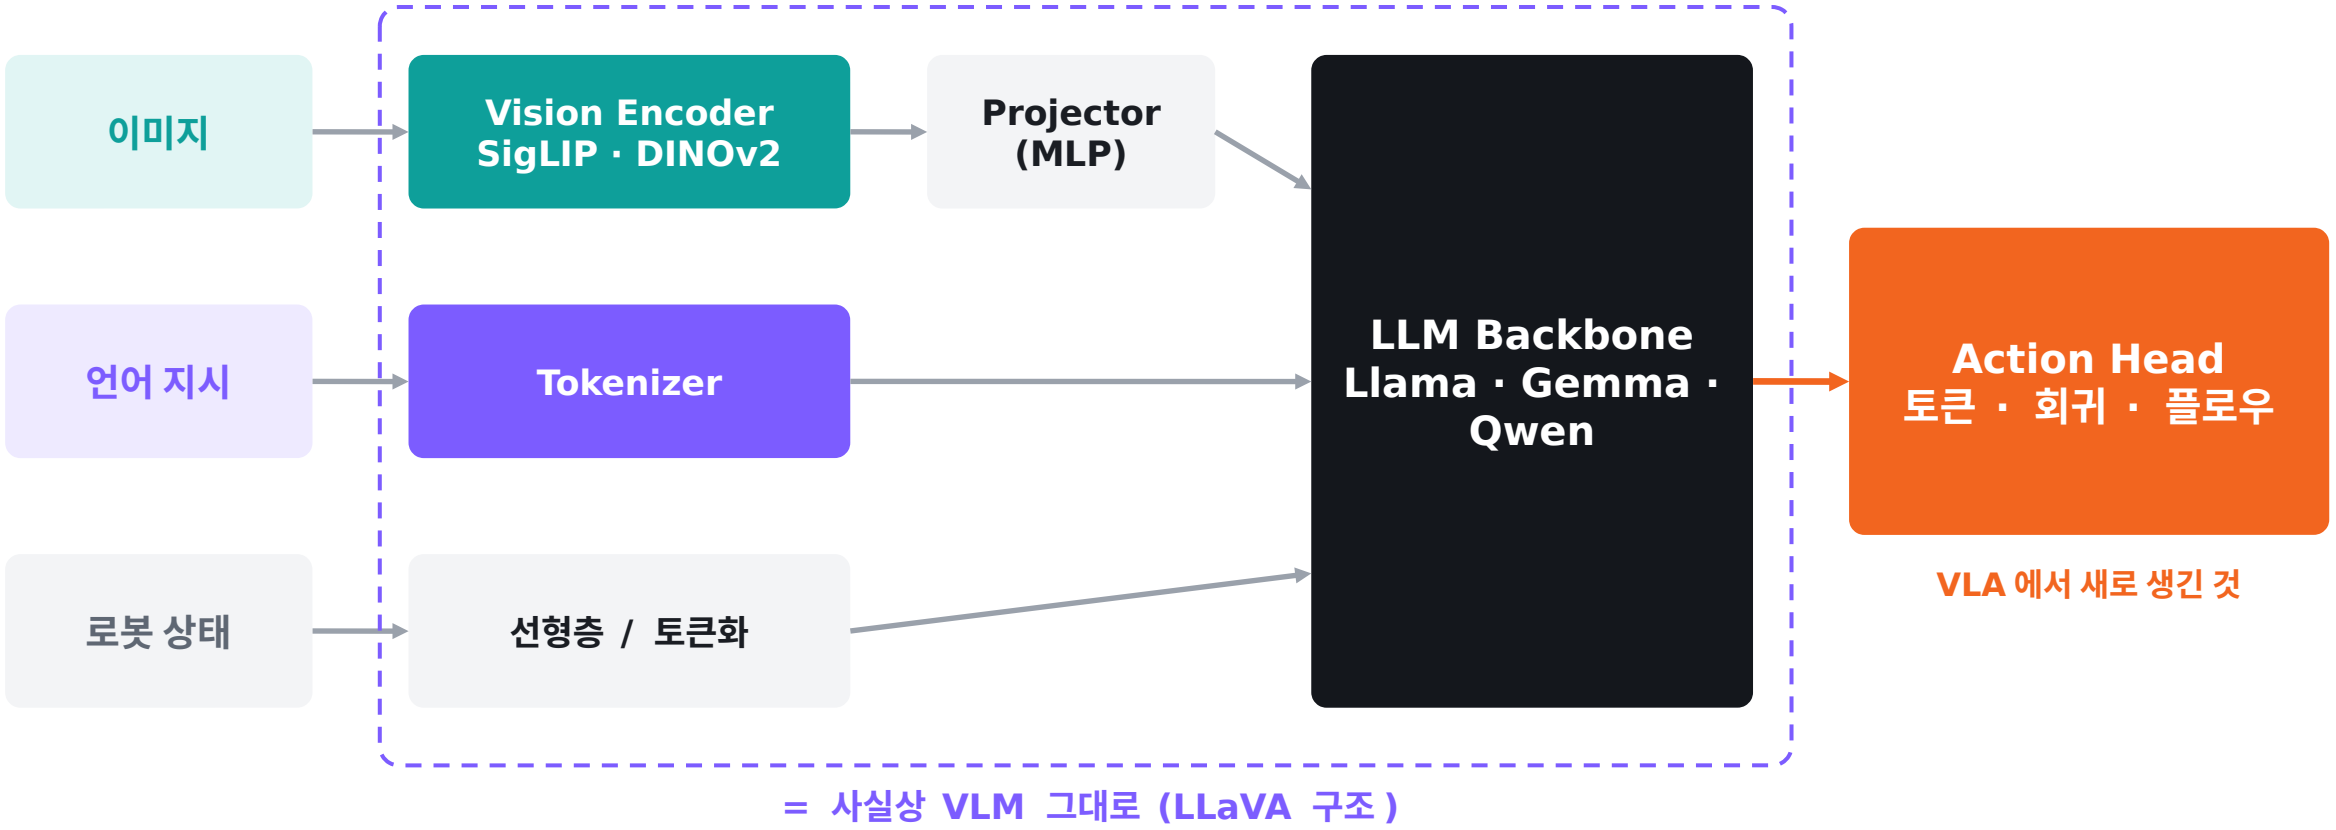
PART 2

VLA 의 구성요소

언어 모델은 '단어'를 출력하는데, 로봇 팔의 움직임은 어떻게 출력하지?

약 25 분 · 슬라이드 15–25

VLA 해부도 : VLM + 행동 출력부



설계 선택의 대부분은 "Action Head 를 어떻게 만들까 ?" 에 있다

Vision Encoder: 이미지를 토큰으로

이미지를 패치로 자름
(224×224, 14×14 패치 → 256 개)



이미지 토큰 = 단어처럼 LLM 에 입력

카메라 여러 대 (머리 + 손목) 면
각각 인코딩해 토큰을 이어 붙임

SigLIP (Google)

이미지 - 텍스트 대조학습 → " 이게 뭔지 " 의미 파악에 강함

DINOv2 (Meta)

자기지도학습 → " 어디에 어떤 모양 " 공간 · 기하 정보에 강함 .
OpenVLA 는 둘을 함께 사용

왜 사전학습된 VLM 을 쓰나 : 인터넷 지식의 전이

" 멸종된 동물을 집어 " → VLM 의 인터넷 지식 : 공룡 = 멸종된 동물 → 공룡 장난감을 집는다

로봇 데이터에 ' 멸종 ' 이라는 단어는 한 번도 없었다 (RT-2 실험)

주의 : 파국적 망각

- 로봇 데이터로만 학습하면 VLM 이 원래 알던 언어 · 상식을 잊어버림
- 해결 ① Co-training: 웹 데이터 (VQA· 캡션) 를 섞어서 함께 학습
- 해결 ② Knowledge Insulation: 행동 헤드의 그래디언트가 VLM 을 망가뜨리지 않게 차단

대표 백본

- RT-2: PaLI-X (55B), PaLM-E (12B)
- OpenVLA: Llama 2 7B (Prismatic)
- π0 / π0.5: PaliGemma 3B
- GR00T: Eagle-2 → Cosmos-Reason
- Gemini Robotics: Gemini

★ 핵심 질문 : 행동을 어떻게 출력할까 ?

1 이산 토큰

행동 값을 256 구간으로 잘라 ' 단어 ' 처럼 분류

RT-1 · RT-2 · OpenVLA

2 연속 회귀

MLP 로 실수 벡터를 바로 출력 (L1/MSE)

OpenVLA-OFT

3 디퓨전 / 플로우 매칭

노이즈에서 시작해 행동을 점점 ' 그려냄 '

Octo · π0 · GR00T

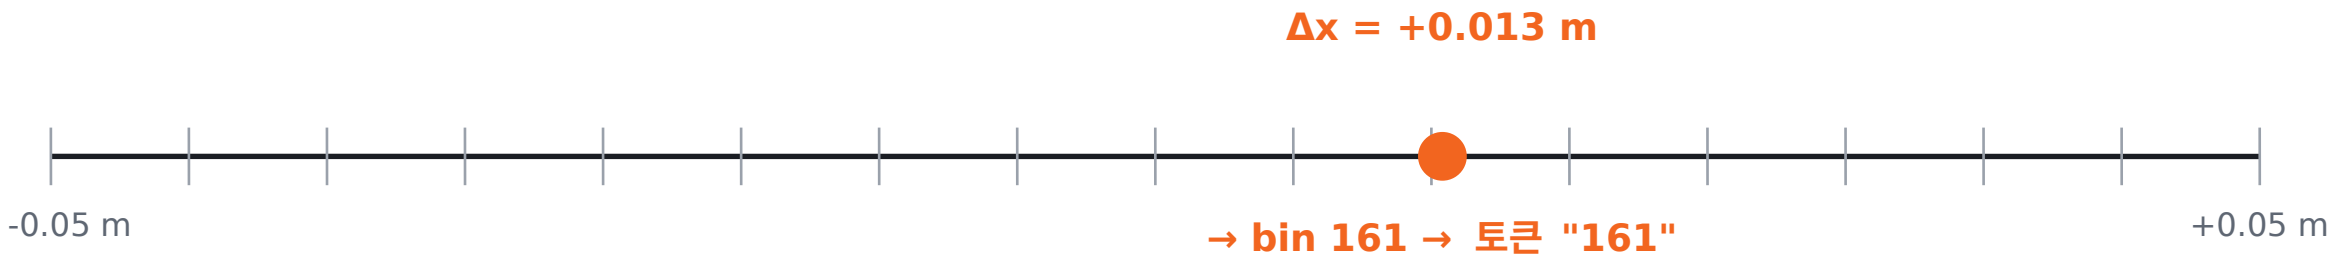
4 압축 토큰 (FAST)

행동 시퀀스를 JPEG 처럼 압축해 토큰화

π0-FAST · π0.5 사전학습

VLA 논문을 읽을 때 가장 먼저 확인할 것

① 이산 토큰화 : 연속 값을 256 칸 눈금으로




```
행동 7 차원 = 토큰 7 개 : "161 98 130 127 140 126 255"
```

장점

- VLM 구조를 전혀 바꿀 필요 없음 (그냥 ' 단어 ' 예측)
- 분류 문제라 여러 정답 (다봉성) 표현 가능

단점

- 해상도 한계 (256 단계)
- 토큰을 하나씩 순차 생성 → 느림 (고주파 제어 불리)

③ 디퓨전 · 플로우 매칭 : 노이즈에서 행동을 그려내기

학습 : $A_\tau = \tau \cdot A + (1-\tau) \cdot \varepsilon \quad \rightarrow \quad v_\theta(A_\tau) \approx A - \varepsilon$



디퓨전

노이즈를 조금씩 걷어내며 생성 (Diffusion Policy, Octo)

플로우 매칭

노이즈 → 정답으로 가는 ' 속도 ' 를 학습 . 직선 경로라 ~10 스텝이면 충분 (π0, GR00T)

왜 좋은가

왼쪽 / 오른쪽 중 하나를 샘플 → 다봉성 해결 , 연속 · 정밀

행동 출력 방식 한눈에 비교

방식	대표 모델	다봉성	정밀도	추론 속도	VLM 변경
① 이산 토큰 (binning)	RT-2, OpenVLA	○	△ (256 단계)	느림 (순차)	없음
② 연속 회귀	OpenVLA-OFT	×	○	매우 빠름 (병렬)	헤드 추가
③ 디퓨전 / 플로우	Octo, π0, GR00T	◎	◎	중간 (~10 스텝 반복)	행동 전문가 추가
④ 압축 토큰 (FAST)	π0-FAST	○	○	느림 (순차)	토크나이저만

정답은 하나가 아니다 → π0.5 처럼 "학습은 토큰 (FAST) 으로, 실행은 플로우로" 섞어 쓰는 하이브리드가 등장

액션 청킹 : 한 스텝씩이 아니라 ' 다음 1 초 ' 를 한 번에



누적 오차 감소

결정 횟수가 1/H 로 → 오류가 쌓일 기회가 줄어듦

시간적 일관성

사람 시연의 ' 잠깐 멈춤 ' 같은 행동도 자연스럽게

속도

무거운 모델을 1 초에 1–2 번만 돌려도 50Hz 제어

실행 요령 : 청크 일부만 실행 후 재예측 (receding horizon) · 겹치는 예측 평균 (temporal ensembling, ACT) · 실행 중 다음 청크 미리 계산 (비동기 / Real-Time Chunking)

④ FAST: 동작을 JPEG 처럼 압축해서 토큰으로

문제 : 50Hz 단순 binning → 1 초에 700 토큰 , 이웃 토큰이 거의 같아 모델이 ' 복사 ' 만 배움

정규화
각 차원을
[-1, 1] 로

→

DCT
주파수 성분으로 변환
(JPEG 과 같은 원리)

→

양자화
반올림 →
고주파 대부분 0

→

BPE 압축
LLM 토크나이저처럼
압축 → 30~60 토큰

≈5 배

학습 속도 향상 (π0-FAST vs π0)
성능은 디퓨전 기반과 비슷

정리

- 토큰 (자기회귀) 방식도 고주파 · 정교한 작업이 가능해짐
- 단점 : 토큰을 순차 생성하므로 추론은 플로우보다 느림
- 범용 토크나이저 FAST+ 공개 → π0.5 사전학습에 사용

데이터셋과 학습 레시피 : LLM 과 똑같은 구조

VLM 사전학습
인터넷 이미지 - 텍스트
(이미 된 것을 가져옴)

→

로봇 사전학습
여러 로봇 · 여러 작업
→ 범용 기초 체력

→

사후학습
목표 로봇 · 목표 작업
고품질 데이터 → 숙련

→

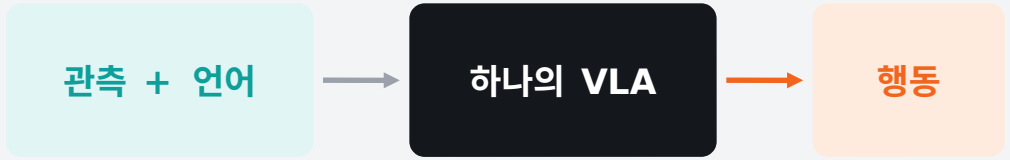
RL · 경험 학습
직접 해보고 개선
(π*0.6, 2025~)

+ Co-training: 로봇 데이터와 웹 데이터를 섞어 상식 유지

데이터셋	연도	규모	특징
Open X-Embodiment	2023	100 만 + 궤적 · 22 종 로봇 · 21 개 기관	" 로봇계의 ImageNet"
DROID	2024	7.6 만 궤적 · 350 시간 · 564 개 장면	실제 다양한 환경의 Franka
π 데이터셋	2024	~1 만 시간 · 7 종 로봇 · 68 개 작업	비공개 (π0 학습용)
LeRobot 허브	2024~	수백 개 커뮤니티 데이터셋	저가 SO-100/101 팔

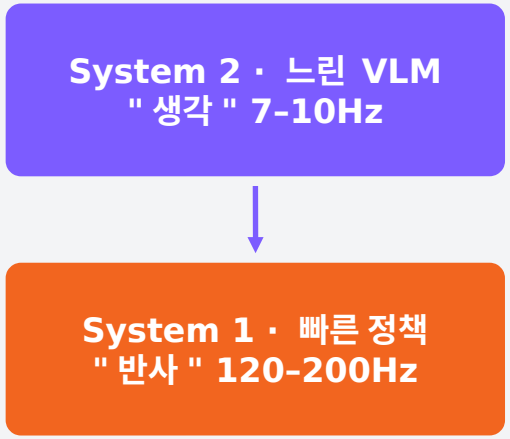
두 가지 아키텍처 계열 : 단일 시스템 vs 이중 시스템

단일 시스템 (Monolithic)



- 예 : RT-2, OpenVLA, π0
- 장점 : 단순 , end-to-end 학습
- 단점 : 모델이 크면 느림

이중 시스템 (Dual-System)



천천히 생각하는 뇌 +
반사적으로 움직이는 척수

- 예 : Figure Helix, NVIDIA GR00T N1, Gemini Robotics
- 장점 : 큰 모델의 지능 + 빠른 제어
- 단점 : 두 시스템 인터페이스 설계



10 분 휴식

쉬는 동안 생각해보기

로봇은 1 초에 50 번 행동해야 하는데 ,
7B 모델 한 번 추론에 150ms 가 걸린다면 어떻게 해야 할까 ?



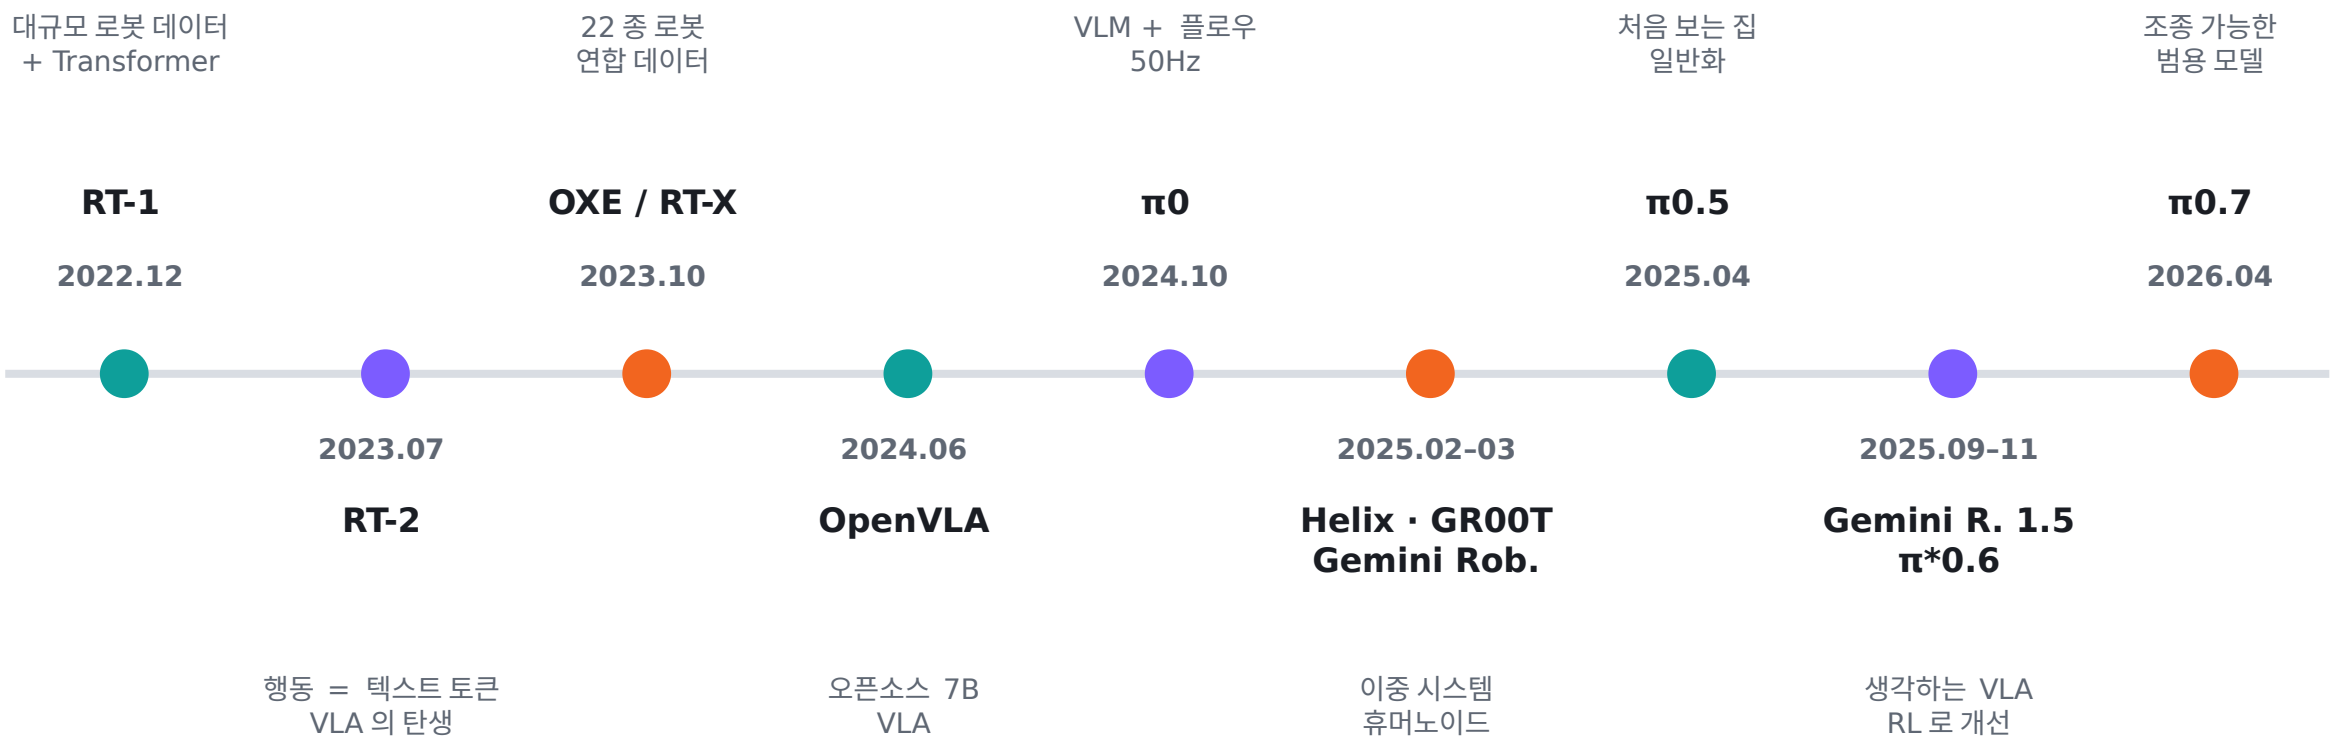
PART 3

논문으로 보는 VLA 의 진화

RT-1(2022) 부터 π0.7(2026) 까지 — 사람들은 이 문제를 어떻게 풀어왔나

약 45 분 · 슬라이드 28–49

VLA 계보 한 장 요약 (2022 → 2026)



큰 흐름 : 전용 모델 → VLM 기반 → 정교한 연속 제어 → 일반화 → 추론 · 경험 학습

배경 : VLA 이전의 두 가지 핵심 기법 (2023)

ACT / ALOHA (Zhao et al.)

- 약 2 만 달러짜리 저가 양팔 원격조종 시스템
- Action Chunking with Transformers: 한 번에 100 스텝 예측
- ~50 개 시연 (10 분) 으로 배터리 끼우기 등 정밀 작업 80–90%
- **→ ' 액션 청킹 ' 을 대중화**

Diffusion Policy (Chi et al.)

- 이미지 생성용 디퓨전으로 행동 시퀀스 생성
- 다봉성을 자연스럽게 표현
- 여러 벤치마크에서 평균 ~47% 향상
- **→ ' 행동 = 생성 모델 문제 ' 관점**

한계 : 작업마다 모델을 따로 학습하는 전문가 (specialist) 정책 , 언어 이해 없음 → VLA 는 이를 하나의 범용 모델로

Google · 2022.12

RT-1: 로봇 13 대 , 17 개월 , 13 만 에피소드



97%
학습한 작업 성공률

76%
처음 보는 지시

700+
수행 가능한 지시 수

한계

인터넷 지식 없음 → 로봇
데이터에 없는 개념은 모름

기억할 것 : ' 행동을 256 구간으로 나눈 분류 ' 아이디어의 원조

★ RT-2: " 행동도 그냥 언어다 "

질문

```
"What action should the robot take to pick up the apple?"
```

VLM 의 정답 (텍스트 !)

1	128	91	241	5	101	127	217
종료	Δx	Δy	Δz	Δroll	Δpitch	Δyaw	그리퍼

Co-fine-tuning (핵심 비법)

로봇 데이터만이 아니라 원래의 인터넷 VQA· 캡션 데이터와 섞어서 학습 → 상식 유지 + 행동 학습

모델

PaLI-X (5B / 55B), PaLM-E (12B)
55B 는 클라우드 TPU 에서 1–3Hz

★ RT-2: 가르치지 않은 능력 (Emergent Capabilities)

" 멸종된 동물을 집어 " → 공룡 장난감

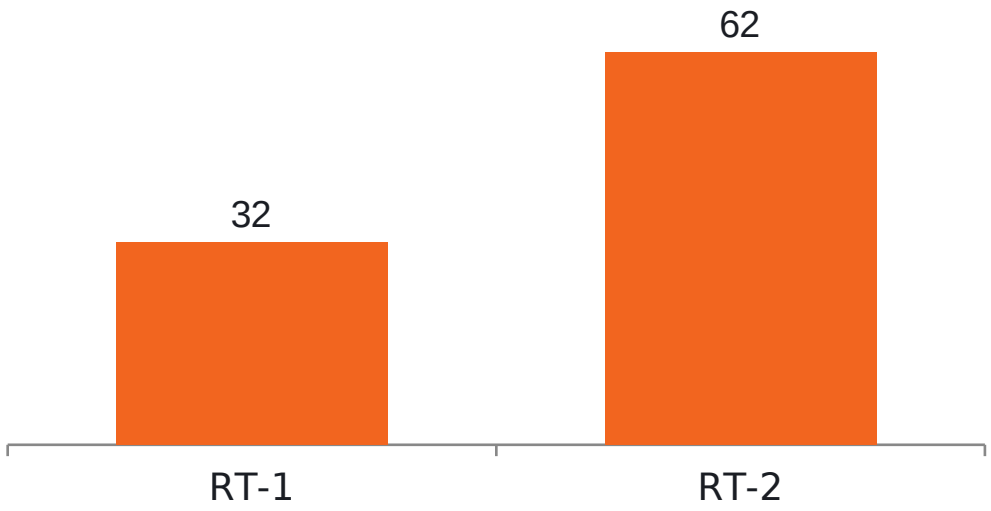
" 즉석 망치로 쓸 물건을 집어 " → 돌

" 콜라를 테일러 스위프트에게 " → 사진 위로

" 바나나를 2+1 의 합으로 " → 숫자 3 위로

변형 : 행동 전에 "Plan: ..." 을 텍스트로 먼저 생성 (Chain-of-thought)

일반화 성공률 (%, 대략값)



한계

새로운 ' 동작 ' 은 못 배움 — 인터넷 지식은 무엇을 · 어디로만 도와줌 . 크고 느리고 비공개 .

Open X-Embodiment & RT-X: 로봇계의 ImageNet

22 종
로봇 형태 (embodiment)

21 개
참여 기관 (34 개 연구실)

100 만 +
궤적 (60 개 데이터셋)

527
기술 (skills)

질문 : 다른 로봇의 데이터도 내 로봇에 도움이 될까 ? (cross-embodiment transfer)

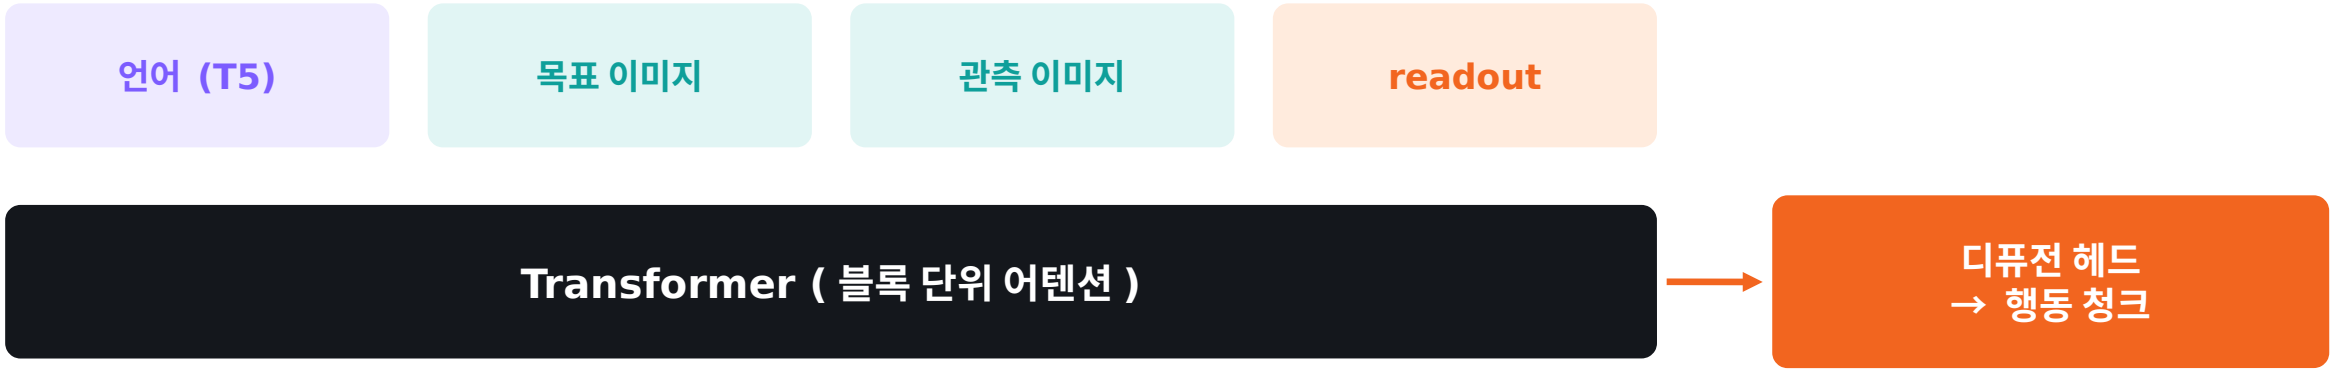
RT-1-X

데이터가 적은 연구실에서 , 각자의 원래 방법 대비 평균 +50%

RT-2-X (55B)

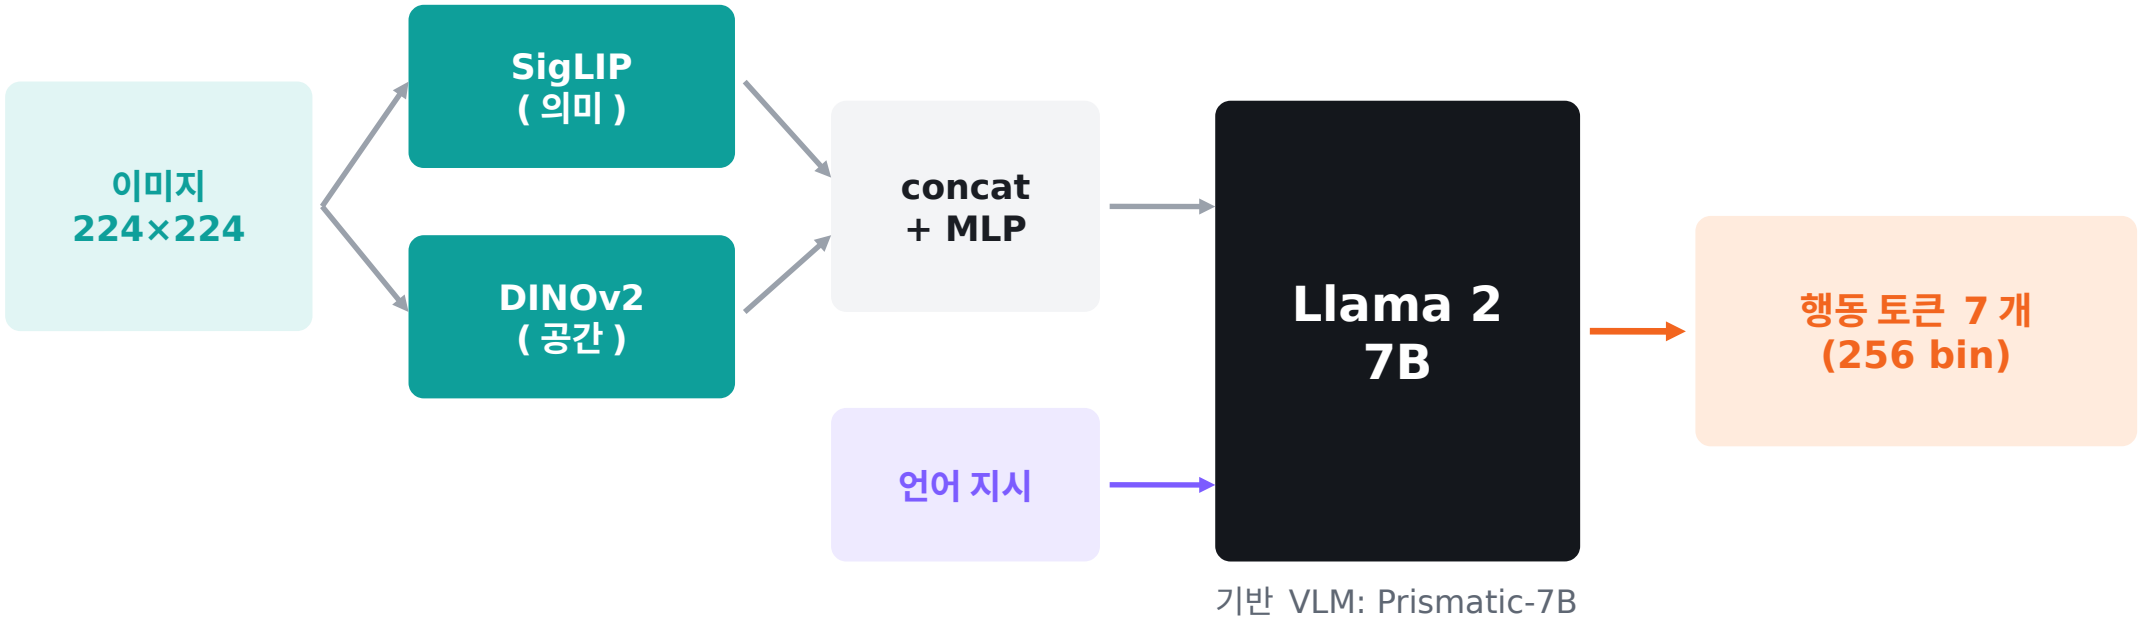
다른 로봇 데이터 덕분에 emergent skill 평가에서 RT-2 대비 약 3 배

Octo: 오픈소스 범용 정책 (디퓨전 헤드)



- OXE 80 만 궤적으로 학습 · 27M / 93M 파라미터 (작음 , VLM 아님)
- readout 토큰 : BERT 의 [CLS] 처럼 정보를 모아 행동 헤드로
- 새 카메라 · 새 행동 공간 → 토큰 / 헤드만 추가 → 파인튜닝 친화적
- 한계 : 언어 이해 · 상식이 약함 → OpenVLA 로

★ OpenVLA: RT-2 레시피를 오픈소스 7B 로



기반 VLM: Prismatic-7B

- 데이터 : OXE 에서 선별한 97 만 궤적 · A100 64 장으로 14 일
- bin 범위 = 1~99 백분위수 (이상치 무시) · 안 쓰는 256 개 토큰을 행동 토큰으로
- 발견 : VLM 과 달리 비전 인코더도 같이 학습해야 성능↑ (로봇엔 세밀한 공간 정보가 중요)

★ OpenVLA: 7 배 작은데 더 잘한다 , 그리고 누구나 쓸 수 있다

+16.5%p

RT-2-X (55B) 대비 절대 성공률
29 개 작업 · 2 종 로봇

7 배

더 적은 파라미터 (7B vs 55B)

+20.4%p

새 로봇 (Franka) 파인튜닝 시
Diffusion Policy(처음부터) 대비

실용성 = 연구의 민주화

- LoRA: 파라미터 1.4% 만 학습해도 전체 파인튜닝과 동등
- 4-bit 양자화로 메모리 절감 , 성능 유지
- 코드 · 가중치 · 데이터 파이프라인 전부 공개

한계

- ~6Hz: 토큰 7 개 순차 생성 , 청킹 없음 → 정밀 작업 불리
- 이미지 1 장 · 로봇 상태 입력 없음
- 256 bin 해상도 한계

Stanford (Kim, Finn, Liang) · 2025.02

OpenVLA-OFT: 행동 출력 방식만 바꿨더니

1 **병렬 디코딩**

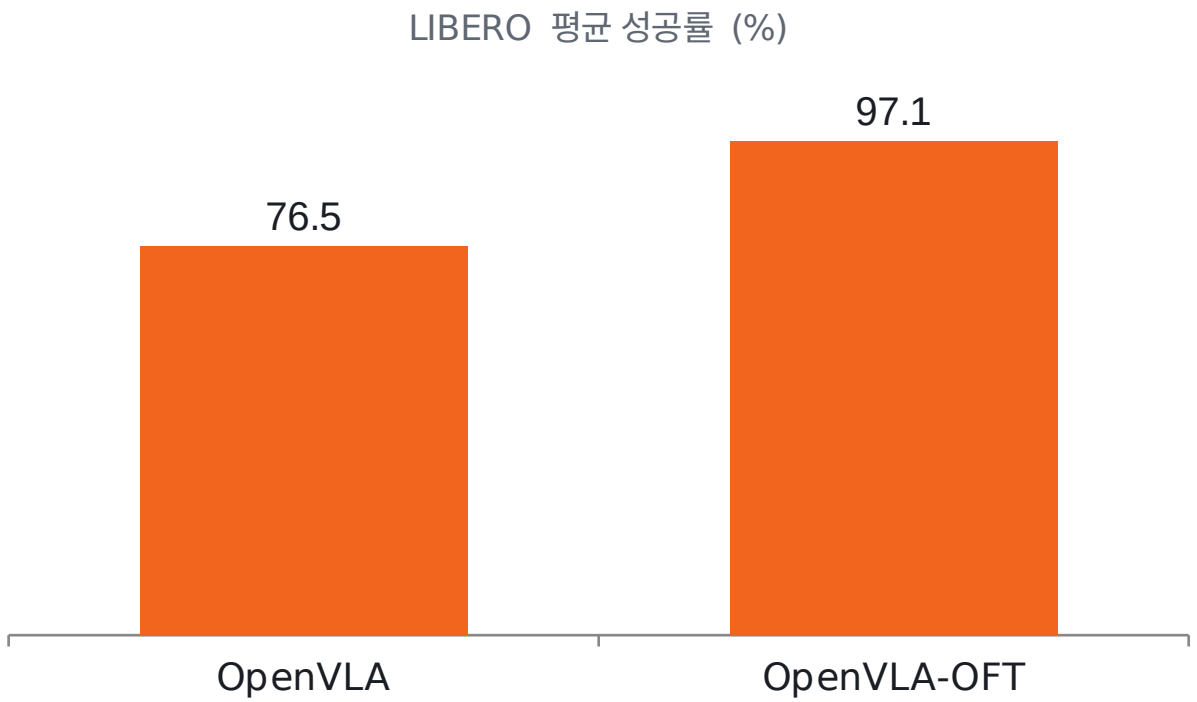
토큰을 하나씩이 아니라
한 번의 forward 로

2 **액션 청킹**

여러 스텝을
한 번에 예측

3 **연속 행동 + L1**

256 bin 대신
MLP 로 실수값 직접



행동 생성 처리량 ~26 배 ↑ · 교훈 : 행동을 ' 토큰 ' 으로 출력하는 게 꼭 최선은 아니다

★ π0: VLM + 플로우 매칭 ' 행동 전문가 '



- 이미지 · 언어는 한 번만 계산 → 캐시
- 행동 부분만 10 번 반복 → 빠름
- 행동 청크 H=50 · 최대 50Hz
- RTX 4090 에서 ~73ms
- 여러 로봇 : 행동 벡터를 zero-padding

★ π0: LLM 처럼 사전학습 → 사후학습

사전학습 (Pre-training)

- 자체 데이터 ~1 만 시간 · 7 종 로봇 구성 · 68 개 작업 + OXE
- 다양하지만 품질은 섞인 데이터
- → **넓은 기초 능력 + 실수에서 회복하는 능력**

→

사후학습 (Post-training)

- 목표 작업의 고품질 데이터 5~100 시간
- 모범 사례 위주
- → **유창하고 능숙한 동작**

비유

사전학습만 하면 → 이것저것 할 줄 알지만 서툼
사후학습만 하면 → 능숙하지만 한 번 실수하면 회복 못 함

★ π0: 처음으로 범용 모델이 해낸 정교하고 긴 작업

빨래 개기

건조기에서 꺼내 → 바구니 → 테이블 → 개기 (수십 분짜리 작업)

테이블 치우기

식기는 통에 , 쓰레기는 휴지통에 분류

상자 조립

납작한 골판지를 접어 상자로

계란 담기

깨지지 않게 계란판에 하나씩

- 사전학습 모델만으로 (zero-shot) 도 OpenVLA · Octo 를 크게 앞섬
- 사전학습을 거친 모델이 사후학습 효율도 훨씬 좋음
- 2025.02 openpi 로 코드 · 가중치 공개 → "VLM + 행동 전문가 " 구조가 사실상 표준으로

FAST · π0-FAST: 토큰 방식의 부활



성능

디퓨전 기반 π0 과 비슷한 성능

학습

약 5 배 빠른 학습 . DROID 로 학습한 모델이 새 환경에서 zero-shot 동작

단점

자기회귀 디코딩이라 추론이 플로우보다 느림

→ π0.5 의 사전학습에 사용 (다음 슬라이드)

★ π0.5: 처음 보는 집에서 일하려면 어떤 데이터가 필요한가

MM 모바일 로봇 데이터
~100 개 집 · ~400 시간

ME 다양한 환경의 고정형 팔
환경 다양성

CE 실험실 다른 로봇 데이터
OXE 포함 · 다양한 기술

HL 고수준 하위작업 라벨
" 베개를 집어라 "

WD 웹 데이터
캡션 · VQA · 물체 위치

VI 사람의 말 코칭
단계별 언어 지시

목표 로봇 데이터 (MM) 는 일부일 뿐 — 나머지 이질적인 데이터가 일반화를 만든다
웹 데이터를 빼면 처음 보는 물체 성능↓ · 학습한 집 ~100 개면 테스트 집에서 직접 학습한 수준에 근접

★ π0.5: 먼저 말하고, 그다음 움직인다



같은 모델이 하위 작업을 텍스트로 예측한 뒤, 그 텍스트를 조건으로 행동 생성 (로봇판 chain-of-thought)

2 단계 학습

- 사전학습 (280k 스텝): 모든 것을 토큰으로 — 행동은 FAST 토큰 → 빠르고 효율적
- 사후학습 (80k 스텝): Action Expert(플로우) 추가 → 실행은 빠르고 정교

Knowledge Insulation (2025.05)

- VLM 은 FAST 토큰으로 학습 (좋은 표현)
- Action Expert 의 그래디언트가 VLM 으로 가지 않게 차단 (stop-gradient)
- → VLM 지식 보존 · 학습 빠름 · 언어 지시 따르기 ↑

이중 시스템 휴머노이드 : Figure Helix & NVIDIA GR00T N1

Helix (Figure)

System 2

7B 오픈 VLM · 7–9Hz
장면 · 언어 이해 → 잠재 벡터

System 1

80M Transformer · 200Hz
손가락까지 상체 35 자유도

- ~500 시간 원격조종 데이터
- VLM 이 영상을 보고 지시문을 역생성해 라벨로
- 두 로봇 협업 , 로봇 탑재 GPU 에서 실행

GR00T N1 (NVIDIA)

System 2

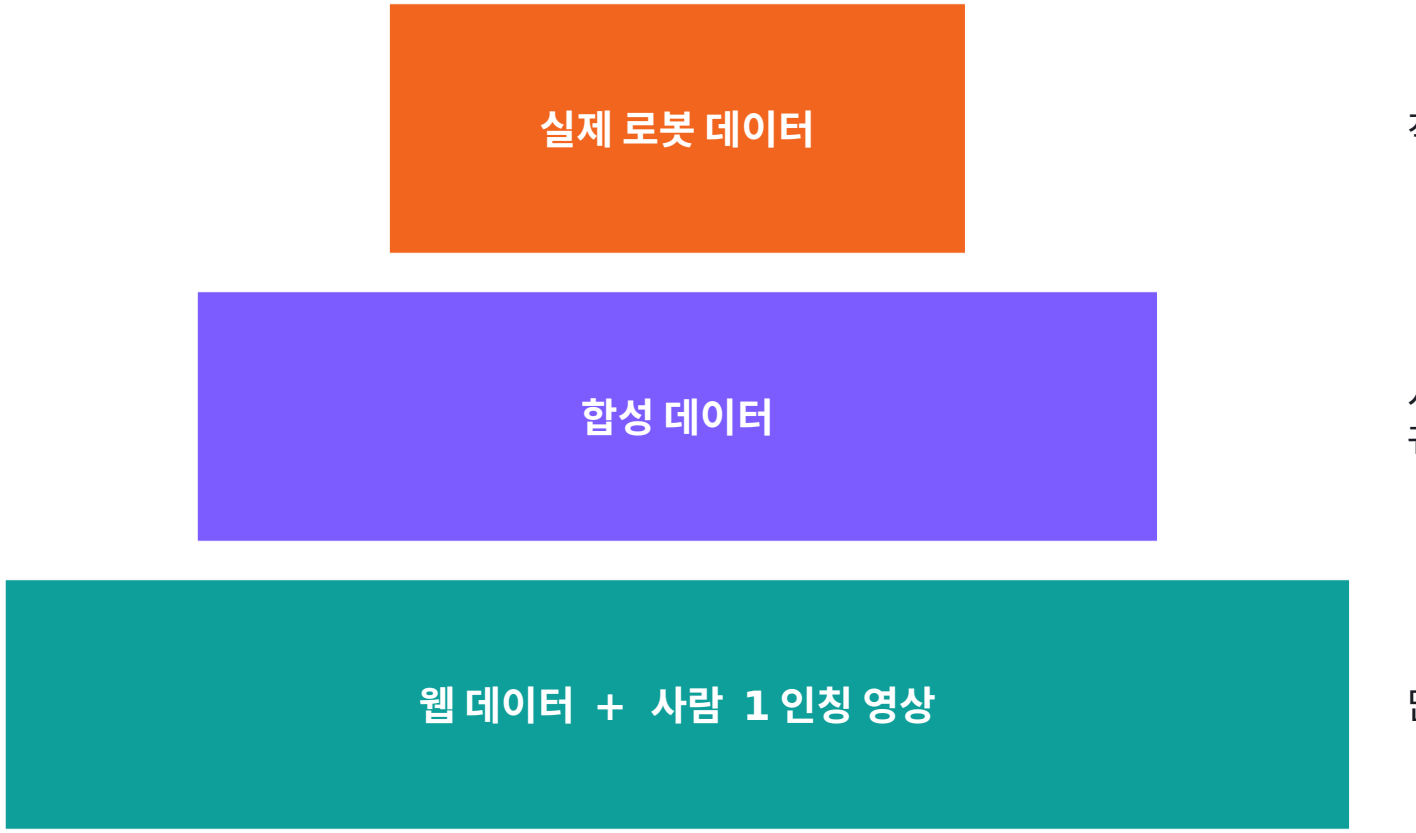
Eagle-2 VLM (1.34B) · ~10Hz
LLM 중간층 특징 사용

System 1

DiT + 플로우 매칭 · 120Hz
16 스텝 청크 (~64ms, L40)

- 전체 2.2B · 오픈 가중치
- 로봇별 인코더 / 디코더 , 몸통 공유
- 후속 N1.5(VLM 고정) · N1.6(Cosmos-Reason, 32 층 DiT)

GR00T N1 의 데이터 피라미드 : 부족한 로봇 데이터를 채우는 법



적음 · 비쌈 · 정확

시뮬레이션 (DexMimicGen) · 영상 생성 모델로 만든 궤적

많음 · 공짜 · 행동 라벨 없음

행동 라벨 없는 영상은 ? → 잠재 행동 (latent action): 앞뒤 프레임 차이에서 ' 가상의 행동 ' 을 학습해 라벨로 사용

Gemini Robotics → 1.5: 생각하고 행동하는 에이전트

Gemini Robotics-ER 1.5
" 지휘자 " · 계획 · 도구 사용 (웹 검색)

↓ 단계별 자연어 지시

Gemini Robotics 1.5 (VLA)
생각 (텍스트) → 행동

예 : " 우리 동네 분리수거 규칙대로 쓰레기를 분류해 " → ER 이 규칙을 검색 → VLA 가 분류

Gemini Robotics

- 2025.03 · Gemini 2.0 기반
- ER: 가리키기 , 3D 박스 , 잡을 위치 등 공간 추론
- 클라우드 백본 + 로컬 액션 디코더 , 청크로 50Hz
- 종이접기 · 도시락 싸기

Gemini Robotics 1.5

- 2025.09 · Think before acting: 행동 전에 자연어로 추론
- Motion Transfer: ALOHA · Franka · 휴머노이드 Apollo 사이 동작 전이
- 2026.04 ER 1.6 (계기판 읽기 등)

π*0.6 · RECAP: 경험과 교정으로 스스로 나아지는 VLA

① 수집
시연 + 자율 시도
+ 사람의 교정

→

② 가치 함수
" 얼마나 잘 되고
있나 " 예측

→

③ 어드밴티지
각 행동이 평균보다
나았나 / 못했나

→

④ 조건부 학습
"Advantage: +/−"
태그 붙여 전부 학습

↻ **반복 · 실행할 땐 항상 "positive" 로 조건 → 좋은 행동 쪽에서 샘플**

2 배 +

가장 어려운 작업의 처리량
(빨래 : 시간당 ~4 개 → 8 개 +)

~½

실패율 감소
(빨래 성공률 ~40% → 75%+)

의미

모방 (시연자 수준에 갇힘) → 경험 (스스로 개선). LLM 의 RLHF · reasoning RL 과 평행 . 에스프레소를 하루 종일 연속 제조 .

π0.7 (2026): 말로 코칭할 수 있는 " 조종 가능한 " 범용 모델

프롬프트에 언어 지시만이 아니라 다양한 ' 컨텍스트 ' 를 함께 넣는다

하위작업 지시
" 먼저 뚜껑을 열어 "

하위목표 이미지
" 이렇게 된 상태로 "

에피소드 메타데이터
품질 · 속도 · 전략

- 서툰 시연 · 실패 · 이전 모델 궤적까지 " 이건 어떤 품질의 데이터 " 라는 태그와 함께 학습 → 실행 시 원하는 품질 지정
- 5B 파라미터 · 범용 모델로 전문가 (파인튜닝) 모델 수준 성능
- 조합적 일반화 : 배운 기술을 재조합 — 말로 단계별 코칭받아 에어프라이어로 고구마 조리
- 아직 : 처음 보는 작업 60–80% vs 학습 분포 내 작업 >90%

주요 VLA 한눈에 비교

모델	연도	크기	백본	행동 출력	공개
RT-1	2022	35M	EfficientNet + Transformer	이산 토큰	일부
RT-2	2023	55B	PaLI-X / PaLM-E	이산 토큰 (텍스트)	×
Octo	2024	93M	Transformer	디퓨전	○
OpenVLA	2024	7B	Llama 2 + SigLIP/DINOv2	이산 토큰	○
π0	2024	3.3B	PaliGemma + Action Expert	플로우 매칭	○
OpenVLA-OFT	2025	7B	OpenVLA	연속 회귀 + 청킹	○
Helix	2025	7B + 80M	이중 시스템	연속 (S1)	×
GR00T N1	2025	2.2B	Eagle-2 + DiT	플로우 매칭	○
π0.5	2025	~3B	PaliGemma + AE	FAST → 플로우	○
Gemini Robotics 1.5	2025	비공개	Gemini	비공개	×
SmolVLA	2025	0.45B	SmolVLM2 + AE	플로우 매칭	○

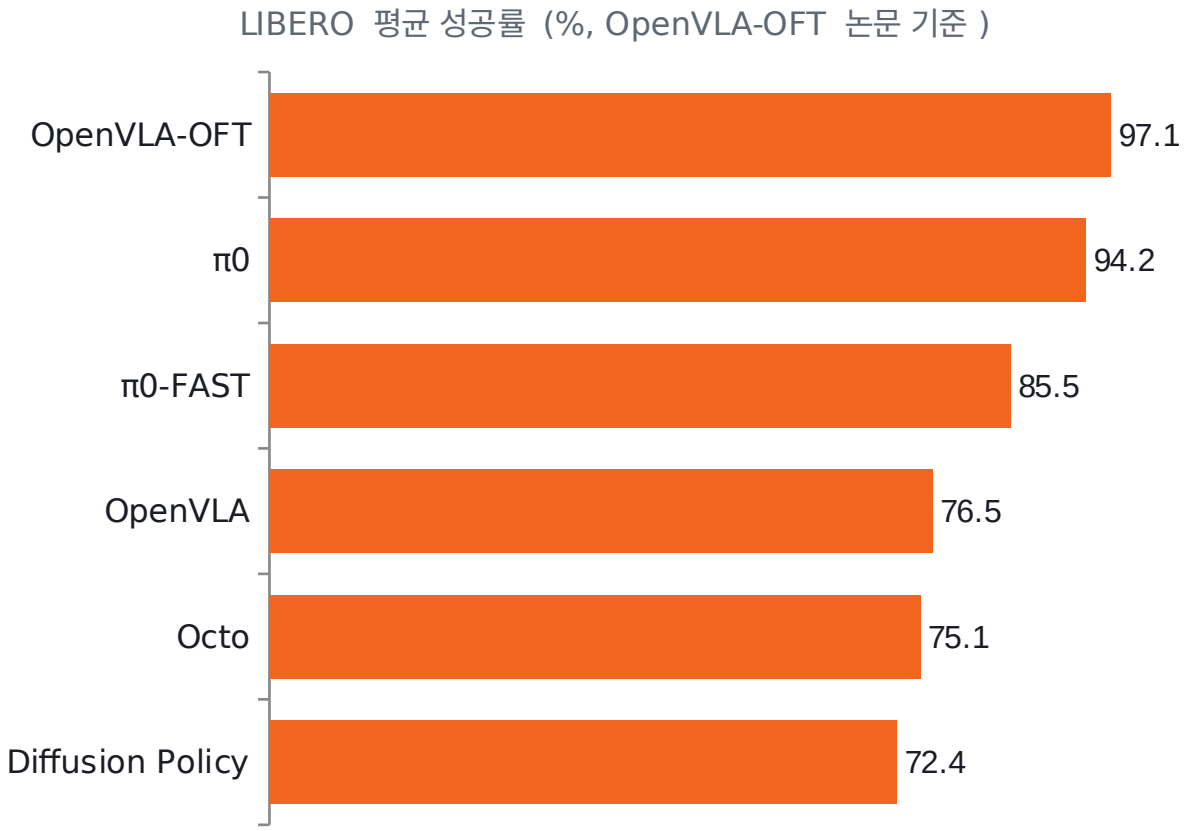
PART 4

평가 · 한계 · 미래

그래서 이제 다 된 걸까 ?

약 10 분 · 슬라이드 51–54

어떻게 평가하나 : 벤치마크와 그 한계



벤치마크	특징
LIBERO	시뮬레이션 , 4 개 스위트 · 포화 상태
SimplerEnv	실제 로봇과 상관된 시뮬 평가
CALVIN	긴 연속 작업 (몇 개 연속 성공 ?)
RoboTwin 2.0	양팔 조작 시뮬
RoboArena 등	여러 기관 분산 실세계 평가

시뮬 97% 여도 실세계는 다르다 → 결국 실제 로봇 평가가 필요하지만 비싸고 재현이 어렵다

아직 남은 과제

데이터

여전히 인터넷보다 수만 배 적다 . 사람 영상 · 시뮬 · 월드 모델로 확장 중

속도 · 효율

큰 모델 = 느림 . 엣지 배포 , 소형화 , 비동기 추론

신뢰성

데모는 되지만 99.9% 는 아직 . 긴 작업에서 누적 실패

안전

VLA 자체엔 안전 보장 없음 → 외부 안전장치 , 안전 추론 연구

정교함 · 감각

촉각 · 힘 제어 , 손가락 조작은 초기 단계

평가

재현 가능한 실세계 평가 방법 부재

2025–26 트렌드 : VLA 는 어디로 가고 있나

모방 → 경험 (RL)	로봇이 직접 해보며 개선 · π*0.6 RECAP, 실세계 RL
생각하는 VLA	행동 전 추론 · ECoT, π0.5 하위작업 예측 , Gemini Robotics 1.5
에이전트 + VLA	고수준 VLM(계획 · 도구) + 저수준 VLA(동작) · Gemini ER, Hi Robot
데이터 확장	사람 1 인칭 영상 · 시뮬 · 영상 생성 월드 모델 · 잠재 행동
작고 빠르고 열린 모델	SmolVLA(450M) · openpi · LeRobot · GR00T 오픈 가중치
조종 가능성 · 코칭	다양한 컨텍스트로 조건화 , 말로 가르치기 · π0.7

직접 해보기 : 오늘 밤부터 시작할 수 있는 것

1	**LeRobot 설치**	Hugging Face 의 로봇 학습 라이브러리 . 데이터셋 · 학습 · 평가 · 시각화
2	**사전학습 모델 받기**	SmolVLA (노트북 GPU) · π0/π0.5 (openpi) · OpenVLA · GR00T
3	**시뮬에서 파인튜닝**	LIBERO / SimplerEnv 데이터로 LoRA 파인튜닝
4	**실제 로봇으로**	SO-101 같은 저가 팔 + 원격조종으로 50 개 시연 → 파인튜닝

`github.com/huggingface/lerobot` · `github.com/Physical-Intelligence/openpi` · `github.com/openvla/openvla`

오늘의 핵심 5 줄

1. VLA = VLM(눈 + 언어) 에 로봇의 손 (행동) 을 붙인 모델
2. 인터넷 지식이 로봇으로 전이된다 (RT-2: 멸종된 동물 → 공룡)
3. 핵심 설계 = 행동 출력 방식 : 토큰 · 회귀 · 디퓨전 / 플로우 · FAST
4. 정교함은 액션 청킹 + 플로우 (π0), 일반화는 데이터 다양성 (π0.5)
5. 다음 단계 : 생각하는 VLA · 경험으로 배우는 VLA(RL) · 말로 코칭

Q & A

추천 읽을거리

RT-2 (2307.15818) · OpenVLA (2406.09246) · π0 (2410.24164) · π0.5 (2504.16054)
서베이 : A Survey on VLA Models — An Action Tokenization Perspective (2507.01925)
실습 : LeRobot · openpi

감사합니다